Universidad de los Llanos
Facultad de Ciencias Básicas e Ingeniería
Ingeniería de Sistemas

Curso: Simulación Computacional

---

# Práctica Número Cinco: Análisis de Datos de Entrada y Ajuste de Datos a Distribuciones de Probabilidad

Secciones 5.1, 5.2 y 5.3

---

David Andrés Monroy
Código estudiantil: 160005019
Ingeniería de Sistemas – Universidad de los Llanos

25 de octubre de 2026

# Índice

**1 Objetivos** **1**

**2 Consulta previa** **1**

**3 Fundamento teórico** **2**

**4 Procedimiento y resultados** **3**

4.1 5.1. Conjunto de datos: análisis preliminar con estadística descriptiva . . . . . 3

4.2 5.2. Análisis de datos de entrada . . . . . 5

4.2.1 a. Correlaciones de retraso estimadas (*Estimated lag correlations*) . . . . . 5

4.2.2 b. Diagrama de dispersión (*Scatter diagram*) . . . . . 6

4.2.3 c. Patrón de hora de llegada (*Arrival time pattern*) . . . . . 7

4.2.4 d. Conteo de llegadas vs intervalos (*Arrival counts vs intervals*) . . . . . 8

4.2.5 e. Gráfico de media móvil (*Moving average plot*) . . . . . 9

4.2.6 Evaluación de los supuestos de independencia y estabilidad . . . . . 10

4.3 5.3. Ajuste de curvas . . . . . 11

4.3.1 Conjunto de datos A . . . . . 13

4.3.2 Conjunto de datos B . . . . . 14

4.3.3 Conjunto de datos C . . . . . 14

4.3.4 Conjunto de datos D . . . . . 15

4.3.5 Las tres distribuciones con mejor ajuste . . . . . 15

4.3.6 Selección de la distribución para cada conjunto de datos . . . . . 18

**5 Conclusiones** **20**

**6 Anexos** **20**

# 1 Objetivos

- Conocer cómo se analizan los datos de entrada en un estudio de simulación, partiendo de muestras tomadas de un proceso o fenómeno del sistema que se quiere estudiar.
- Revisar si los valores de una muestra se pueden tratar como una variable aleatoria independiente (sin correlación) y estacionaria.
- Comparar qué tan bien se ajustan varias distribuciones de probabilidad a un mismo conjunto de datos, usando la suma de errores cuadráticos (SSE) y los criterios de información de Akaike (AIC) y Bayesiano (BIC).
- Escoger, para cada conjunto de datos, la distribución que mejor lo representa para poder usarla después en una simulación.

# 2 Consulta previa

**¿En qué consiste la estadística descriptiva?** Es la parte de la estadística que se encarga de organizar y resumir un conjunto de datos, sin sacar conclusiones sobre la población completa de donde salieron. Para esto usa medidas de tendencia central (media, mediana y moda), medidas de dispersión (rango, varianza, desviación estándar y rango intercuartílico), medidas de posición (cuartiles y percentiles) y medidas de forma (asimetría y curtosis). También se apoya en gráficos como histogramas, diagramas de caja y diagramas de dispersión. En simulación es lo primero que se hace con los datos de entrada, porque da una idea de su escala y su forma y ayuda a pensar qué distribuciones vale la pena probar.

**¿Qué son la asimetría estadística (*skewness*), la curtosis y los percentiles?** La asimetría indica qué tan desbalanceada está una distribución alrededor de su media. Se calcula como

$$\gamma_1 = \frac{E\big[(X-\mu)^3\big]}{\sigma^3}.$$

Cuando $\gamma_1 = 0$ la distribución es simétrica, como la normal. Si $\gamma_1 > 0$ la distribución tiene una cola larga hacia la derecha, como pasa con la exponencial ($\gamma_1 = 2$), la lognormal o la gamma. Si $\gamma_1 < 0$, la cola larga queda hacia la izquierda.

La curtosis indica qué tan pesadas son las colas de la distribución, es decir, qué tan seguido aparecen valores extremos. Normalmente se reporta el exceso de curtosis,

$$\gamma_2 = \frac{E\big[(X-\mu)^4\big]}{\sigma^4} - 3,$$

que para la normal vale 0. Si $\gamma_2 > 0$ (leptocúrtica) la distribución tiene colas pesadas y los valores extremos son más comunes; si $\gamma_2 < 0$ (platicúrtica) las colas son ligeras.

Los percentiles dicen en qué posición está un valor dentro de los datos: el percentil $p$ es el valor que deja por debajo al $p$ % de las observaciones. Los cuartiles son percentiles especiales: $Q_1$ es el percentil 25, $Q_2$ el 50 (la mediana) y $Q_3$ el 75. La resta $Q_3 - Q_1$ es el rango intercuartílico, que mide la dispersión sin dejarse afectar mucho por los valores atípicos.

**¿Qué significa y en qué consiste el supuesto de que un conjunto de variables aleatorias sea IID?** IID quiere decir independientes e idénticamente distribuidas. Que las variables $X_1, X_2, \ldots, X_n$ sean independientes significa que conocer el valor de una no dice nada sobre las otras (por ejemplo, $\mathrm{Cov}(X_i, X_{i+k}) = 0$ para cualquier retraso $k \neq 0$). Que sean idénticamente distribuidas significa que todas salen de la misma distribución, con la misma forma y los mismos parámetros, sin importar en qué momento se tomaron. Este supuesto es el que permite ajustar una sola distribución a toda la muestra y luego generar valores independientes de ella en la simulación. Si no se cumple, el modelo de entrada tiene que tener en cuenta la dependencia o los cambios en el tiempo.

**¿En qué consiste un proceso estocástico estacionario?** Un proceso estocástico $\{X_t\}$ es estacionario cuando su comportamiento no cambia con el tiempo. De forma estricta, esto significa que la distribución conjunta de $(X_{t_1}, \ldots, X_{t_n})$ es la misma que la de $(X_{t_1+h}, \ldots, X_{t_n+h})$ para cualquier corrimiento $h$. En la práctica se suele usar una versión más sencilla, la estacionariedad débil: la media y la varianza se mantienen constantes y la covarianza entre $X_t$ y $X_{t+k}$ solo depende de la distancia $k$ entre ellas. Por ejemplo, un proceso de llegadas cuya tasa cambia durante el día (un proceso de Poisson no homogéneo) no es estacionario.

**¿En qué consiste un proceso estocástico correlacionado?** Es un proceso en el que cada observación depende de las anteriores. Esto se nota porque existe autocorrelación, es decir,

$$\rho_k = \frac{\mathrm{Cov}(X_t, X_{t+k})}{\sigma^2} \neq 0$$

para algún retraso $k$. Un ejemplo es el proceso autorregresivo $X_t = \alpha X_{t-1} + (1-\alpha)U_t$, donde después de un valor alto suele venir otro valor alto. Si un proceso así se simula como si fuera IID, se tiende a subestimar la variabilidad del sistema y medidas como el tiempo de espera en una cola salen distorsionadas.

## 3 Fundamento teórico

La práctica se basa en el Capítulo 3 (*Input Data Analysis*) del *Handbook of Simulation* [1], sobre todo en la sección 3.4, que trata sobre cómo comprobar la independencia y la estabilidad de los datos, y en la sección 3.5, que explica cómo escoger la forma de la distribución cuando los datos son IID. También se tuvo en cuenta la presentación de clase *3. Input Data Analysis*. Para el ajuste de las distribuciones se siguió el tutorial de Amat Rodrigo [2] y los notebooks de ejemplo del curso.

En la sección 5.1 se describen los cuatro conjuntos de datos con estadística descriptiva e histogramas. En la sección 5.2 se revisa si los datos son independientes y estacionarios; para eso cada conjunto se trata como una lista de tiempos entre llegadas $x_1, \ldots, x_{200}$, de modo que el instante de cada llegada es $t_i = \sum_{j \leq i} x_j$ y el tiempo total observado es $T = \sum_i x_i$. En la sección 5.3 se ajustan nueve distribuciones a cada conjunto por máxima verosimilitud y se comparan con tres métricas. En las tres, entre más bajo el valor, mejor es el ajuste:

$$\mathrm{SSE} = \sum_{j=1}^{20} \left(\hat{f}_j - f(c_j; \hat{\theta})\right)^2, \qquad \mathrm{AIC} = 2k - 2\ln \hat{L}, \qquad \mathrm{BIC} = k \ln n - 2 \ln \hat{L},$$

donde $\hat{f}_j$ es la altura del histograma (de 20 clases) en el centro de la clase $c_j$, $f(\cdot; \hat{\theta})$ es la densidad de la distribución ajustada, $\ln \hat{L} = \sum_i \ln f(x_i; \hat{\theta})$ es la log-verosimilitud, $k$ es la cantidad de parámetros

que se estimaron y $n = 200$. El SSE compara la curva con la forma del histograma, por lo que su valor cambia según el número de clases y la escala de los datos. El AIC y el BIC usan todos los datos y castigan a los modelos con más parámetros; el BIC los castiga más que el AIC.

# 4 Procedimiento y resultados

Todo el trabajo se hizo en Python (con NumPy, pandas, SciPy, statsmodels y Matplotlib) en el notebook `Lab6_Analisis_datos_entrada_y_bondad_de_ajuste.ipynb`, que se entrega junto con este informe. Cada archivo `dataset-X.txt` tiene 200 valores positivos, uno por línea.

## 4.1 5.1. Conjunto de datos: análisis preliminar con estadística descriptiva

Para cada conjunto se calcularon las medidas que pide la guía (Tabla 1). La varianza y la desviación estándar se calcularon como muestrales, es decir, dividiendo entre $n - 1$. Además, para entender mejor la forma de los datos, se calcularon el coeficiente de variación, la asimetría, el exceso de curtosis y el rango intercuartílico (Tabla 2).

Tabla 1: Descripción estadística de los conjuntos de datos A, B, C y D.

| Medida estadística | Dataset A | Dataset B | Dataset C | Dataset D |
|---|---|---|---|---|
| Tamaño de la muestra | 200 | 200 | 200 | 200 |
| Mínimo | 0.020964 | $8.5160 \times 10^{-5}$ | 0.92668 | 0.1115 |
| Máximo | 0.29897 | 1.5513 | 6669.9 | 17.967 |
| Media | 0.19504 | 0.20539 | 762.39 | 2.0605 |
| Varianza | 0.0019193 | 0.052481 | $8.5217 \times 10^{5}$ | 5.413 |
| Desviación estándar | 0.04381 | 0.22909 | 923.13 | 2.3266 |
| Percentil 25 % (Q1) | 0.16384 | 0.046329 | 152.91 | 0.63429 |
| Percentil 50 % (Q2 o mediana) | 0.19207 | 0.13768 | 455.56 | 1.4064 |
| Percentil 75 % (Q3) | 0.23011 | 0.29018 | 1028.6 | 2.5289 |

Tabla 2: Medidas complementarias de forma y dispersión.

| Medida | Dataset A | Dataset B | Dataset C | Dataset D |
|---|---|---|---|---|
| Coef. de variación (s/media) | 0.2246 | 1.115 | 1.211 | 1.129 |
| Asimetría (skewness) | −0.2895 | 2.406 | 2.482 | 3.16 |
| Exceso de curtosis | 0.309 | 7.974 | 9.101 | 14.09 |
| Rango intercuartílico (Q3-Q1) | 0.06627 | 0.2439 | 875.7 | 1.895 |

En la Figura 1 se presenta el histograma de cada conjunto con 20 particiones (*bins*).

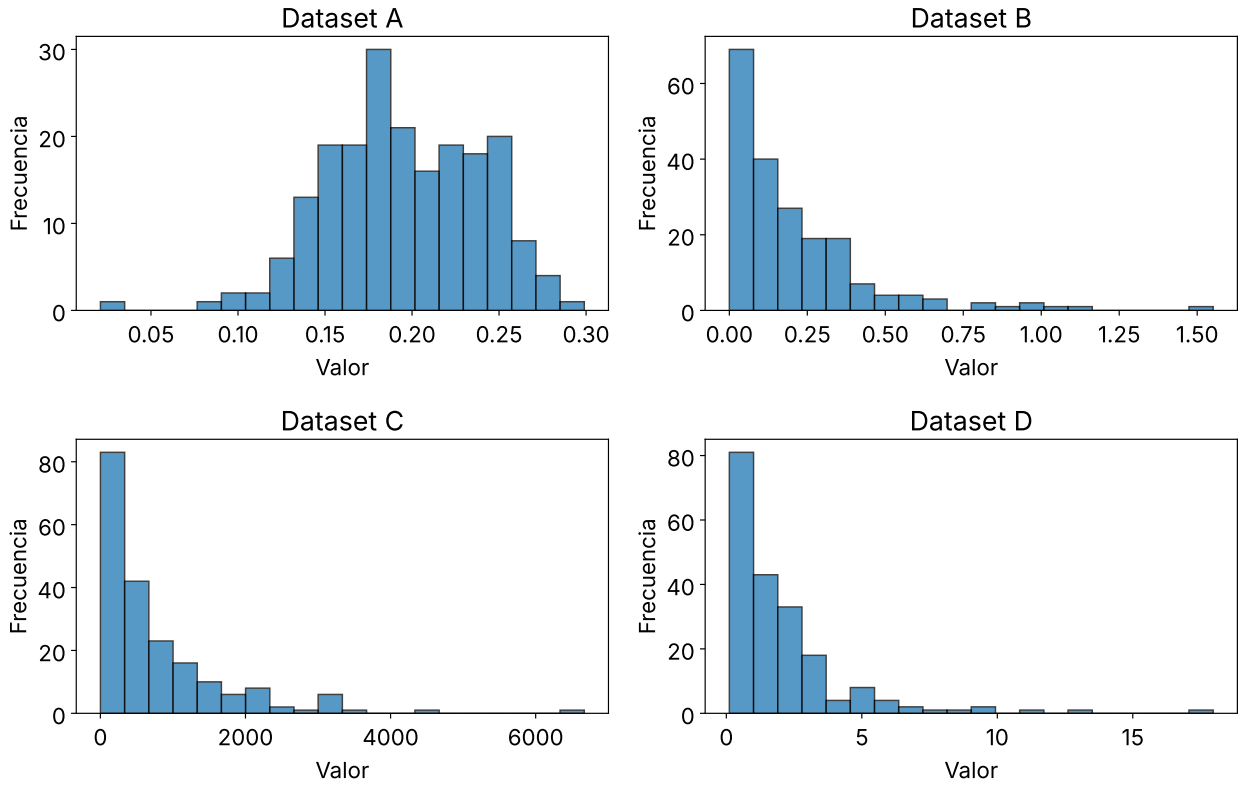



Figura 1: Histogramas de distribuciones de los conjuntos de datos A, B, C y D (20 *bins*).

**¿Qué se puede analizar de las medidas de estadística descriptiva y los histogramas?**

- En el dataset A los valores están en un rango corto (de 0.021 a 0.299). La media (0.195) y la mediana (0.192) son casi iguales, la dispersión es baja (CV $\approx 0.22$) y la asimetría es apenas negativa ($-0.29$). El histograma tiene un solo pico y forma de campana, casi simétrica. Por eso se pensó en la normal, en la Weibull con parámetro de forma alto, en la beta o en la gamma con forma grande. La exponencial no parecía buena opción, porque supone un CV igual a 1 y el pico en cero.

- En el dataset B el mínimo es casi cero y la media (0.205) se parece mucho a la desviación estándar (0.229), así que el CV es cercano a 1 (1.1). La mediana (0.138) es bastante menor que la media y la asimetría es de 2.4. El histograma baja desde cero y tiene una cola larga a la derecha. Esa forma es típica de la exponencial (que tiene CV $= 1$ y asimetría $= 2$), aunque también podría servir una gamma o una Weibull con forma cercana a 1.

- El dataset C maneja una escala muy distinta a los demás (de 0.93 a 6 670). La media (762) es mucho mayor que la mediana (456), la desviación estándar (923) supera a la media (CV $\approx 1.2$), la asimetría es de 2.5 y el exceso de curtosis de 9.1. Casi todos los datos están cerca de cero y hay una cola muy larga a la derecha, lo que hace pensar en una exponencial, una gamma o una Weibull con forma menor que 1. Más adelante, en la sección 5.2, se vio que estos datos no son estacionarios.

- En el dataset D la media (2.06) es mayor que la mediana (1.41), el CV es de 1.1, la asimetría de 3.2 y el exceso de curtosis de 14.1. Hay valores muy grandes, de hasta 17.97, que están a unas

7.8 desviaciones estándar por encima de la media. El histograma está cargado a la izquierda con una cola derecha muy pesada, y el mínimo (0.11) no está pegado a cero como en B. Esto apunta a una lognormal o una log-logística, aunque la exponencial y la gamma también se consideraron.

En general, A es simétrico y con poca dispersión, mientras que B, C y D son positivos y cargados hacia la derecha, con colas cada vez más pesadas. Con estas medidas no se puede saber si los datos son IID; eso se revisa en la sección 5.2.

## 4.2 5.2. Análisis de datos de entrada

Tomando como base el notebook *Example. Input Data Analysis.ipynb*, cada conjunto se trató como una lista de tiempos entre llegadas. Las funciones para graficar del notebook de clase se modificaron un poco para mostrar los cuatro conjuntos en una sola figura y para que funcionaran cuando $T$ no es un número entero. En la versión original el ancho de los intervalos se calculaba con `round(T/nbins)`, que da 0 cuando $T$ es pequeño (en A y B, $T \approx 39$ y $T \approx 41$), y el conteo usaba `counts[k-1]`, lo que mandaba el primer intervalo al final. En la Figura 2 se muestran los valores en el orden en que se observaron.

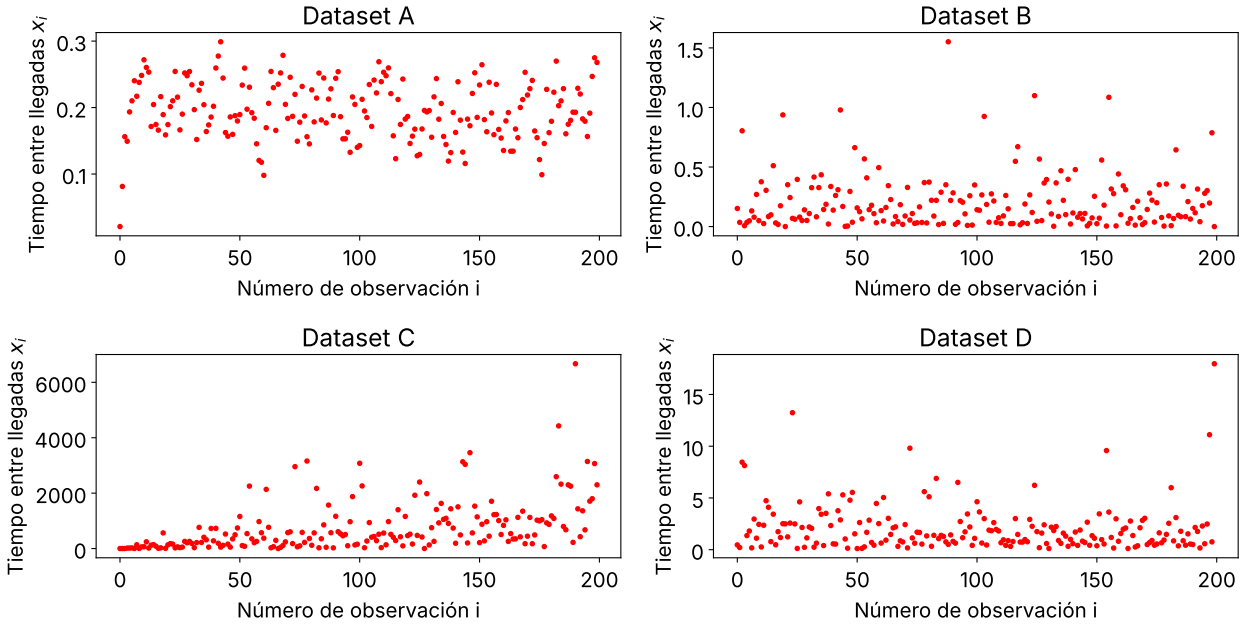



Figura 2: Secuencia de observaciones $x_i$ de cada conjunto de datos en orden de observación.

### 4.2.1 a. Correlaciones de retraso estimadas (*Estimated lag correlations*)

Se calculó la autocorrelación de la muestra $\hat{\rho}_k$ para los retrasos $k = 1, \ldots, 20$ (Figura 3). La zona sombreada es el intervalo de confianza del 95 % si los datos fueran independientes, que es más o menos $\pm 1.96/\sqrt{n} = \pm 0.139$; los valores que se salen de esa zona indican correlación. Además se aplicó la prueba de Ljung-Box con 10 retrasos, que parte de suponer que los datos son independientes (Tabla 3).

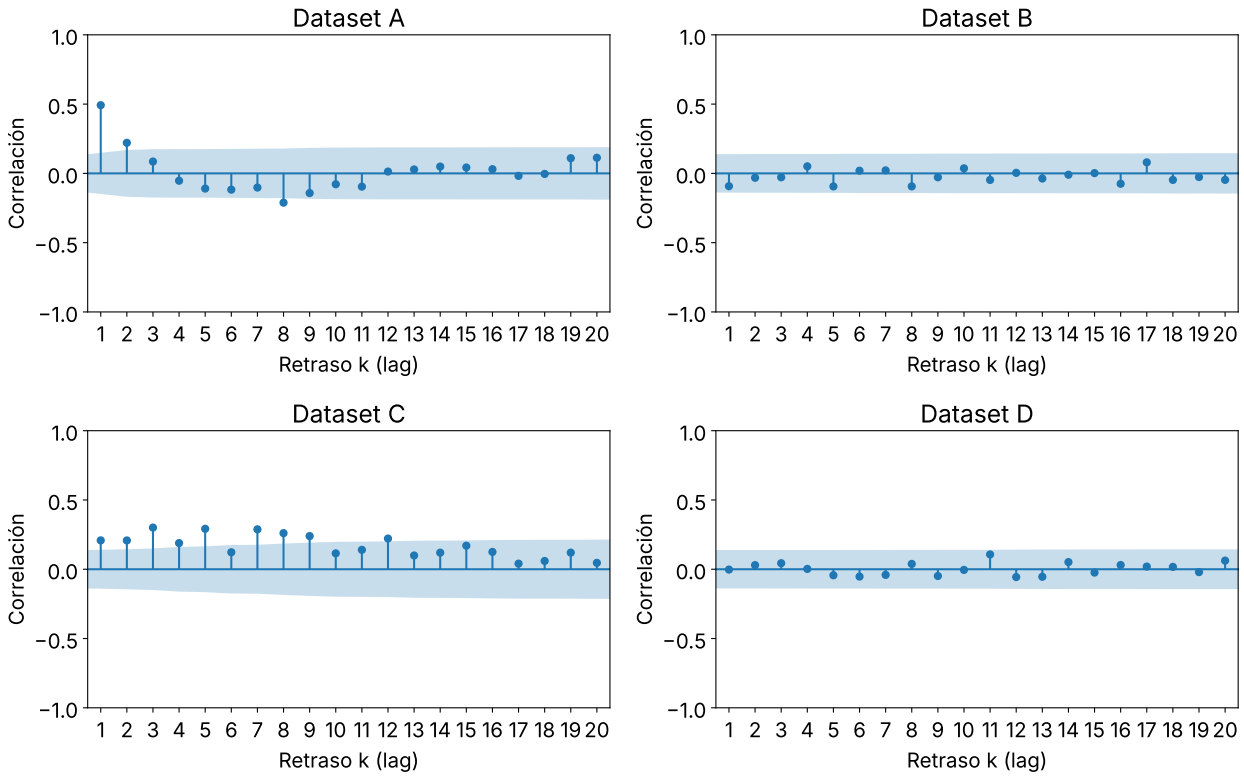



Figura 3: Correlaciones de retraso estimadas (función de autocorrelación) para $k = 1, \ldots, 20$.

Tabla 3: Autocorrelaciones de los primeros retrasos y prueba de independencia de Ljung-Box.

| Medida | Dataset A | Dataset B | Dataset C | Dataset D |
|---|---|---|---|---|
| $\hat{\rho}_1$ | 0.492 | −0.0923 | 0.208 | −0.00238 |
| $\hat{\rho}_2$ | 0.221 | −0.0315 | 0.208 | 0.0298 |
| $\hat{\rho}_3$ | 0.0855 | −0.0282 | 0.301 | 0.0435 |
| $\hat{\rho}_4$ | −0.0529 | 0.0508 | 0.189 | 0.00247 |
| $\hat{\rho}_5$ | −0.11 | −0.0942 | 0.292 | −0.0435 |
| Retrasos fuera de $\pm 1.96/\sqrt{n}$ $(k \leq 20)$ | 4 | 0 | 11 | 0 |
| Ljung-Box, valor $p$ $(k = 10)$ | $9.45 \times 10^{-14}$ | 0.731 | $3.54 \times 10^{-19}$ | 0.987 |

### 4.2.2 b. Diagrama de dispersión (*Scatter diagram*)

En la Figura 4 cada punto representa una pareja de valores seguidos $(x_k, x_{k+1})$. Si los datos son independientes, los puntos quedan regados sin ningún patrón. Si forman una nube alargada sobre la diagonal, hay correlación positiva.

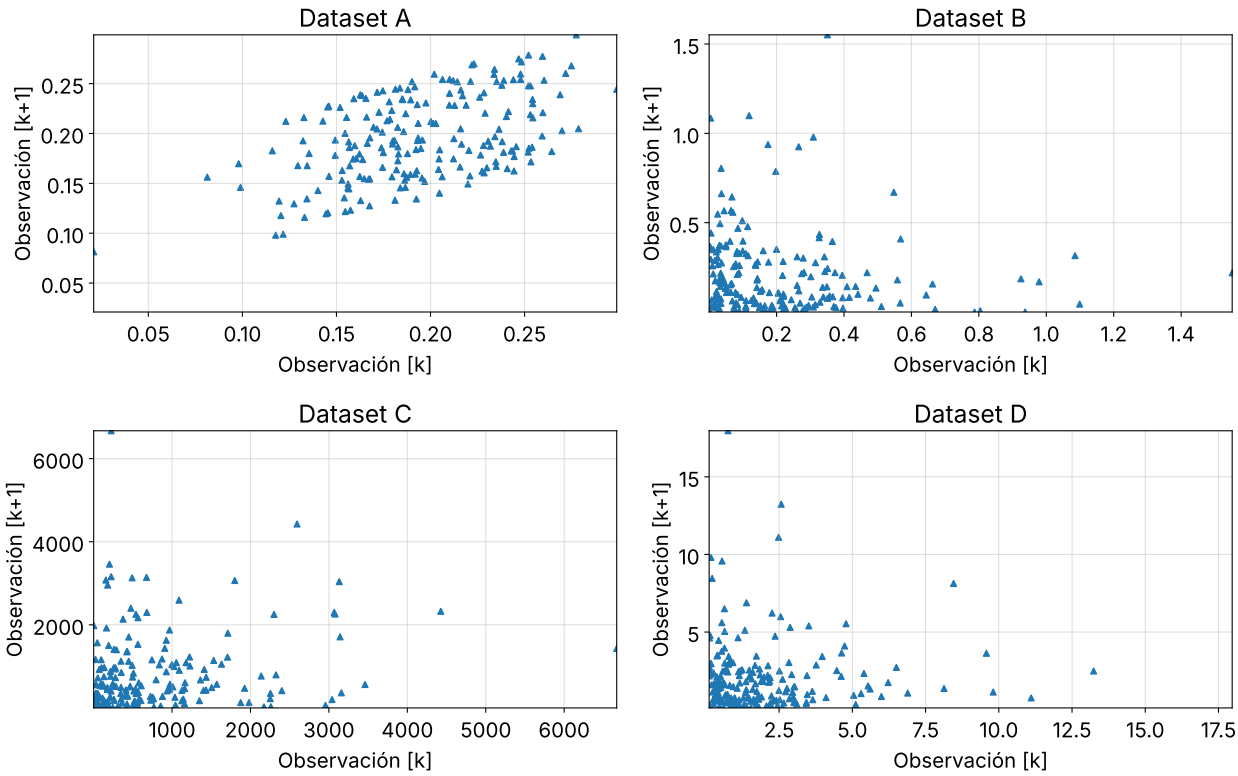



Figura 4: Diagrama de dispersión de observaciones consecutivas $x_k$ frente a $x_{k+1}$.

### 4.2.3 c. Patrón de hora de llegada (*Arrival time pattern*)

En la Figura 5 se grafica qué proporción de las llegadas ya había ocurrido en cada tiempo $T$. Si la tasa de llegadas es constante, la curva debería ir pegada a la diagonal punteada.

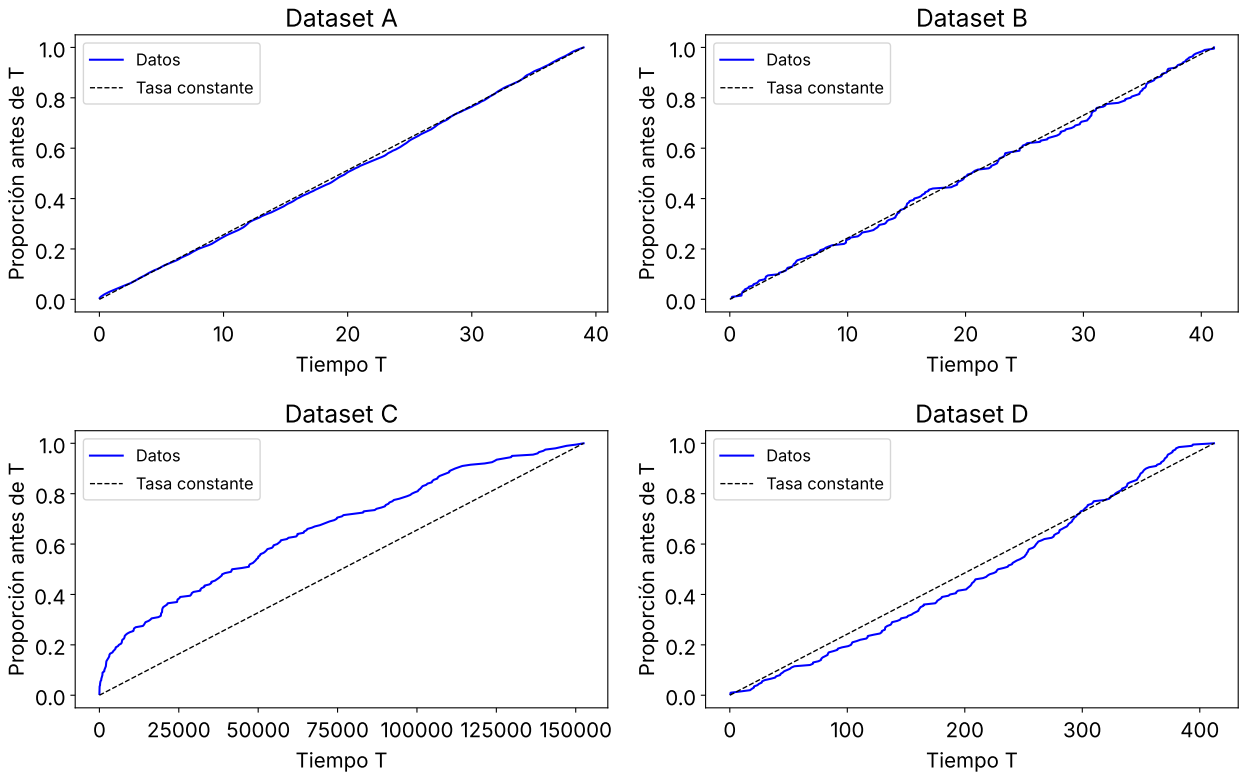



Figura 5: Patrón de hora de llegada: proporción de llegadas antes del tiempo $T$.

#### 4.2.4 d. Conteo de llegadas vs intervalos (*Arrival counts vs intervals*)

El tiempo total $[0, T]$ se partió en 40 intervalos iguales y se contó cuántas llegadas cayeron en cada uno (Figura 6). Si la tasa es constante, cada intervalo debería tener alrededor de $200/40 = 5$ llegadas (línea roja).

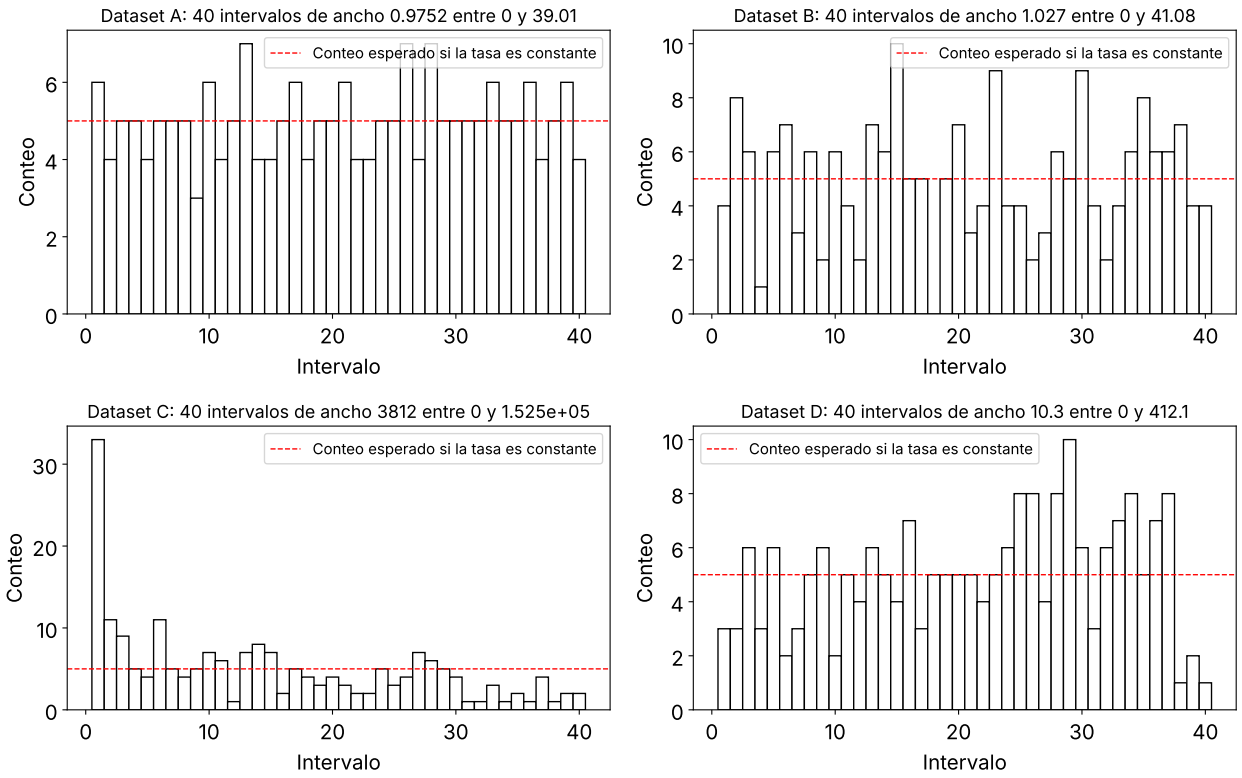



Figura 6: Conteo de llegadas en 40 intervalos de igual ancho entre 0 y $T$.

### 4.2.5 e. Gráfico de media móvil (*Moving average plot*)

Se graficó la media móvil con una ventana de $W = 20$, junto con la media general y las bandas de $\pm 3\sigma$ (Figura 7). En el notebook de clase se usaba $W = 100$ para unos 1 000 datos; como aquí solo hay 200, se dejó una ventana del 10 % de la muestra. Si la secuencia es estable, la media móvil sube y baja alrededor de la media sin una tendencia clara. Para confirmar lo que se ve en la gráfica, se calculó la correlación de Spearman entre la posición $i$ y el valor $x_i$, y se compararon las medias de la primera y la segunda mitad de los datos (Tabla 4).

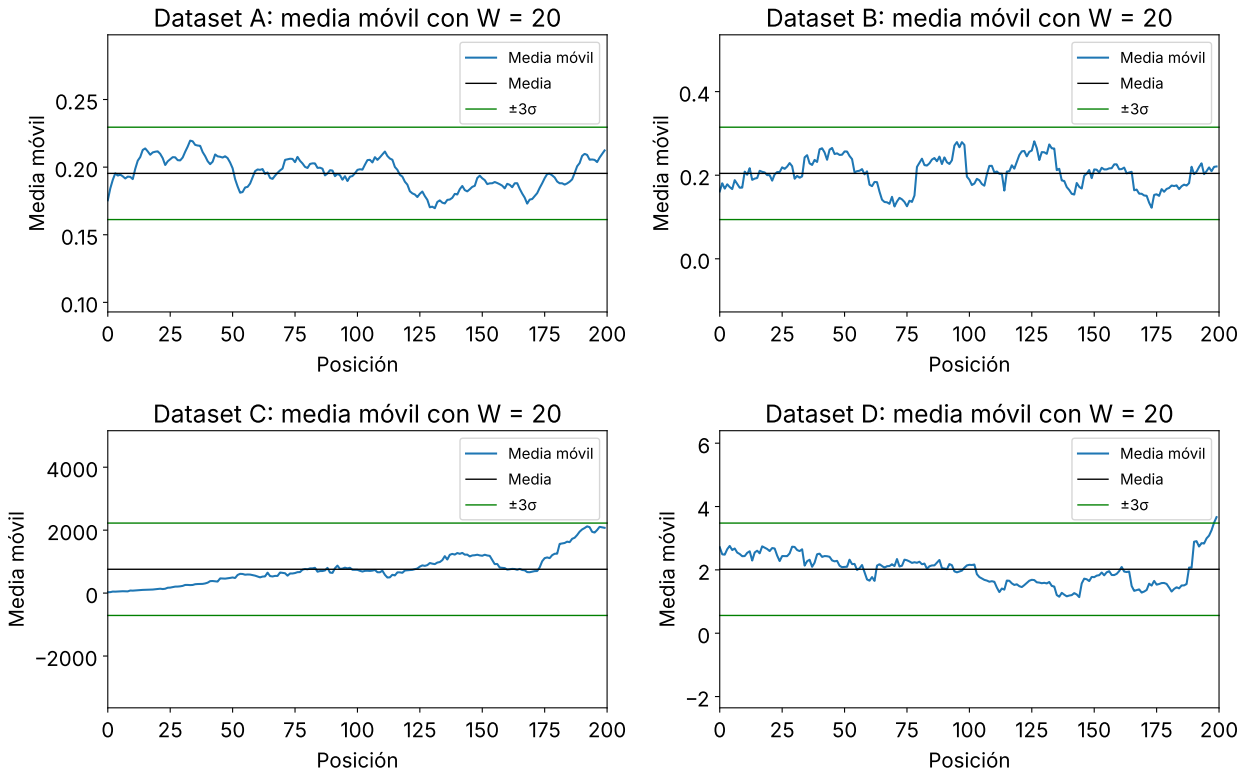



Figura 7: Gráfico de media móvil con ventana $W = 20$ y bandas de $\pm 3\sigma$.

Tabla 4: Prueba de tendencia: correlación de Spearman entre posición y valor, y medias por mitades.

| Medida | Dataset A | Dataset B | Dataset C | Dataset D |
|---|---|---|---|---|
| $\rho$ de Spearman $(i, x_i)$ | $-0.1048$ | $-0.00348$ | $0.6034$ | $-0.1171$ |
| Valor $p$ | $0.1397$ | $0.961$ | $3.212 \times 10^{-21}$ | $0.09866$ |
| Media 1.ª mitad $(i \leq 100)$ | $0.1988$ | $0.205$ | $417.6$ | $2.283$ |
| Media 2.ª mitad $(i > 100)$ | $0.1913$ | $0.2058$ | $1107$ | $1.838$ |

### 4.2.6 Evaluación de los supuestos de independencia y estabilidad

**Dataset A: correlacionado pero estable.** En la autocorrelación se obtuvo $\hat{\rho}_1 \approx 0.49$ y $\hat{\rho}_2 \approx 0.22$, ambos fuera de la banda de confianza, y después los valores caen rápido. Ese comportamiento es el de un proceso autorregresivo de orden 1, parecido al *Set 6* del notebook de clase. En el diagrama de dispersión los puntos forman una nube alargada sobre la diagonal, o sea que después de un valor alto suele venir otro alto. La prueba de Ljung-Box rechaza la independencia ($p \approx 10^{-13}$). Por otro lado, el patrón de llegadas sigue la diagonal, los conteos por intervalo se mueven alrededor de 5, la media móvil se queda dentro de las bandas y no hay una tendencia significativa ($p = 0.14$). Se concluye que el proceso es estacionario pero sus valores no son independientes, así que no cumple el supuesto IID. Una distribución puede describir bien cómo se reparten los valores, pero para simular este proceso de forma fiel habría que incluir la dependencia, por ejemplo con un modelo AR(1).

**Dataset B: cumple el supuesto IID.** Todas las autocorrelaciones quedan dentro de la banda de confianza y la prueba de Ljung-Box no rechaza la independencia ($p = 0.73$). En el diagrama de dispersión no aparece ningún patrón; los puntos se amontonan cerca del origen porque la mayoría de los valores son pequeños, igual que en el *Set 1* exponencial del ejemplo. El patrón de llegadas va sobre la diagonal, los conteos por intervalo varían al azar alrededor de 5 y la media móvil no muestra tendencia (las dos mitades tienen casi la misma media: 0.205 y 0.206). Se concluye que este proceso es independiente y estacionario, por lo que se puede representar con una sola distribución.

**Dataset C: no es estacionario.** En este conjunto los valores y la media móvil van aumentando con el tiempo. La media de la segunda mitad (1 107) es casi 2.7 veces la de la primera (418), y la correlación de Spearman entre la posición y el valor es $\rho \approx 0.60$ ($p \approx 10^{-21}$). El patrón de llegadas se aleja de la diagonal: hay muchas llegadas al comienzo y cada vez menos hacia el final. En los conteos por intervalo pasa lo mismo, con 33 llegadas en el primer intervalo (cuando se esperaban 5) y solo 1 o 2 en los últimos. Es decir, como los tiempos entre llegadas se van alargando, cada vez llegan menos clientes. La autocorrelación es positiva y no baja con el retraso (está entre 0.2 y 0.3 en muchos retrasos y 11 de los 20 se salen de la banda); esto se debe a la tendencia de los datos más que a una dependencia entre valores seguidos. Por lo tanto, C no cumple el supuesto IID, de forma parecida a los *Sets 4 y 5* (Poisson no homogéneo) del ejemplo de clase. Si se ajusta una sola distribución a todo el conjunto se están mezclando momentos con comportamientos diferentes; lo correcto sería modelar la tasa como una función del tiempo o ajustar una distribución por cada tramo.

**Dataset D: cumple el supuesto IID.** Las autocorrelaciones son casi cero (Ljung-Box, $p = 0.99$) y el diagrama de dispersión no tiene ningún patrón. El patrón de llegadas sigue bastante de cerca la diagonal. En los conteos y en la media móvil se ve que los valores bajan un poco en la segunda mitad (media de 1.84 contra 2.28), pero la media móvil no se sale de las bandas de $\pm 3\sigma$, excepto al final por el valor de 17.97 que es la última observación. Además, la prueba de tendencia no sale significativa (Spearman, $p \approx 0.10$). Por eso se considera que D es independiente y estacionario y se puede modelar con una sola distribución, de forma parecida al *Set 3* lognormal del ejemplo. Con más datos se podría confirmar si esa pequeña bajada es solo casualidad.

### 4.3 5.3. Ajuste de curvas

Con base en el tutorial de [2] y los notebooks de ejemplo, se ajustaron por máxima verosimilitud (`scipy.stats.<dist>.fit`) las cinco distribuciones que pide la guía y otras cuatro escogidas por el estudiante (Tabla 5).

Tabla 5: Distribuciones de probabilidad evaluadas.

| Distribución | `scipy.stats` | Justificación |
|---|---|---|
| Exponencial | `expon` | Exigida por la guía. |
| Lognormal | `lognorm` | Exigida por la guía. |
| Normal | `norm` | Exigida por la guía. |
| Gamma | `gamma` | Exigida por la guía. |
| Beta | `beta` | Exigida por la guía. |
| Weibull (1) | `weibull_min` | Generaliza la exponencial; muy usada para tiempos de servicio y de vida. |
| Log-logística (2) | `fisk` | Similar a la lognormal, con cola algo más pesada. |
| Rayleigh (3) | `rayleigh` | Caso particular de la Weibull (forma = 2) para tiempos positivos. |
| Gumbel (4) | `gumbel_r` | Valor extremo, sesgada a la derecha. |

**Consideraciones para el ajuste.**

- Como todos los datos son positivos (son tiempos entre llegadas), en las distribuciones que solo aceptan valores desde cero se fijó el parámetro de localización en 0 (`floc=0`). Al dejar ese parámetro libre, SciPy daba ajustes sin sentido en varios casos, como una gamma con forma de 0.008 en C o un AIC infinito para la Weibull en B y D, porque la localización quedaba por encima del dato más pequeño.
- La beta solo trabaja en el intervalo $[0, 1]$ y los datos no están en ese rango. Por eso se usó la versión de cuatro parámetros, con localización 0 y escala fija en $1.01 \cdot \text{máx}(x)$ para que todos los datos quedaran dentro, y solo se estimaron los dos parámetros de forma $a$ y $b$.
- La normal y la Gumbel se ajustaron dejando libres sus dos parámetros (localización y escala).
- En las tablas, el asterisco (*) marca los parámetros que se fijaron y no se estimaron, y $k$ es el número de parámetros estimados que entra en el AIC y el BIC. El mejor valor de cada métrica está en negrita. También se agregó el valor $p$ de la prueba de Kolmogórov-Smirnov (KS) como dato adicional; hay que tomarlo con cuidado, porque los parámetros se estimaron con los mismos datos que se están probando. La columna Rango es el promedio de las posiciones (de 1 a 9) que obtuvo cada distribución en SSE, AIC y BIC.

En la Figura 8 se ven las nueve curvas ajustadas sobre el histograma de cada conjunto. La línea más gruesa corresponde a la de menor AIC.

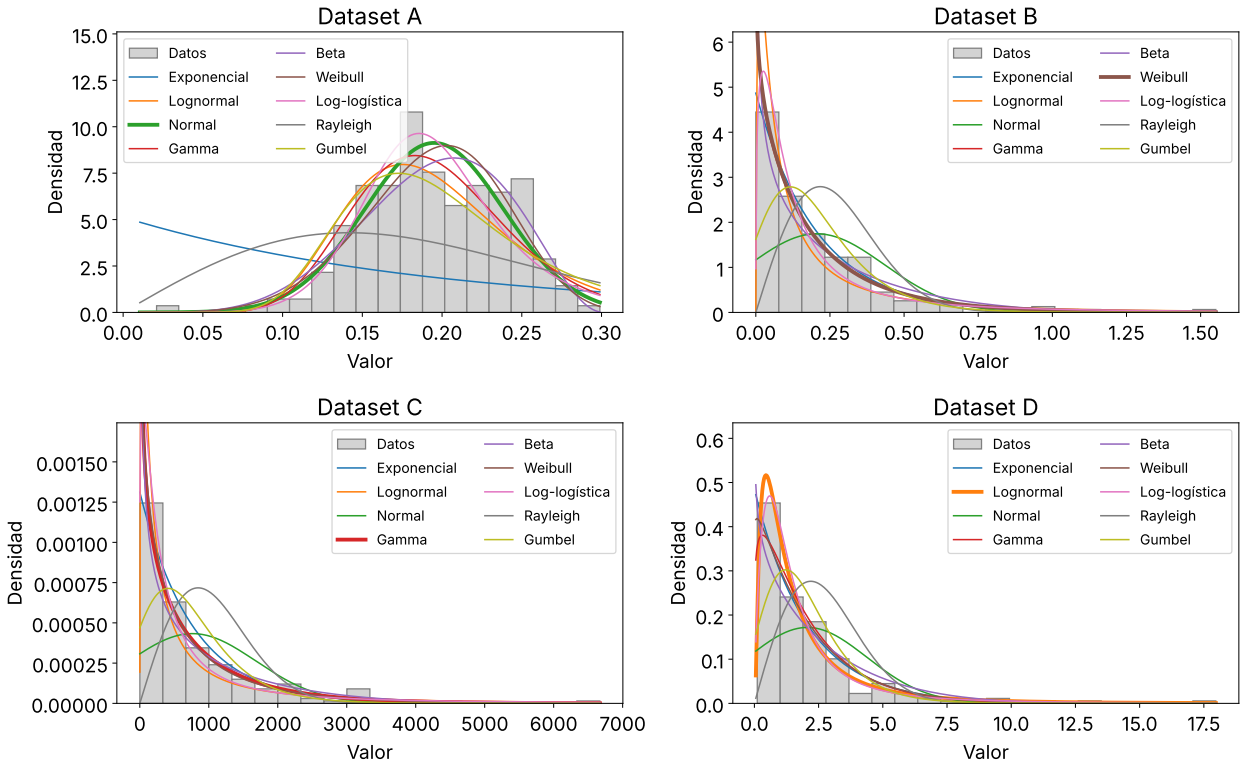



Figura 8: Todas las distribuciones ajustadas sobre el histograma normalizado de cada conjunto de datos.

### 4.3.1 Conjunto de datos A

Tabla 6: Bondad de ajuste para el conjunto de datos A.

| Distribución | Parámetros | $k$ | SSE | AIC | BIC | KS $p$ | Rango |
|---|---|---|---|---|---|---|---|
| Exponencial | loc $= 0^*$, scale $= 0.195$ | 1 | 340.5 | $-251.82$ | $-248.52$ | $1.71 \times 10^{-34}$ | 9.00 |
| Lognormal | $s = 0.275$, loc $= 0^*$, scale $= 0.189$ | 2 | 36.97 | $-611.09$ | $-604.49$ | 0.143 | 6.67 |
| Normal | loc $= 0.195$, scale $= 0.0437$ | 2 | 29.15 | $\mathbf{-680.59}$ | $\mathbf{-673.99}$ | 0.626 | 1.33 |
| Gamma | $a = 16.18$, loc $= 0^*$, scale $= 0.01206$ | 2 | **28.24** | $-647.34$ | $-640.75$ | 0.537 | 3.67 |
| Beta | $a = 5.902$, $b = 3.234$, loc $= 0^*$, scale $= 0.302^*$ | 2 | 29.36 | $-675.74$ | $-669.14$ | 0.195 | 3.00 |
| Weibull | $c = 5.071$, loc $= 0^*$, scale $= 0.212$ | 2 | 32.43 | $-679.36$ | $-672.76$ | 0.292 | 2.67 |
| Log-logística | $c = 7.293$, loc $= 0^*$, scale $= 0.1927$ | 2 | 33.42 | $-655.44$ | $-648.85$ | 0.479 | 4.33 |
| Rayleigh | loc $= 0^*$, scale $= 0.1413$ | 1 | 185.2 | $-497.00$ | $-493.70$ | $3.28 \times 10^{-17}$ | 8.00 |
| Gumbel | loc $= 0.1728$, scale $= 0.0491$ | 2 | 42.53 | $-620.45$ | $-613.85$ | 0.0149 | 6.33 |

### 4.3.2 Conjunto de datos B

Tabla 7: Bondad de ajuste para el conjunto de datos B.

| Distribución | Parámetros | $k$ | SSE | AIC | BIC | KS $p$ | Rango |
|---|---|---|---|---|---|---|---|
| Exponencial | loc $= 0^*$, scale $= 0.2054$ | 1 | 0.4358 | $-231.13$ | $\mathbf{-227.83}$ | 0.336 | 2.33 |
| Lognormal | $s = 1.437$, loc $= 0^*$, scale $= 0.104$ | 2 | 2.326 | $-188.73$ | $-182.14$ | 0.137 | 6.00 |
| Normal | loc $= 0.2054$, scale $= 0.2285$ | 2 | 11.57 | $-18.89$ | $-12.29$ | $1.98 \times 10^{-6}$ | 8.00 |
| Gamma | $a = 0.8636$, loc $= 0^*$, scale $= 0.2378$ | 2 | 0.3158 | $-232.10$ | $-225.50$ | 0.949 | 2.33 |
| Beta | $a = 0.6894$, $b = 4.115$, loc $= 0^*$, scale $= 1.567^*$ | 2 | 1.111 | $-207.31$ | $-200.71$ | 0.138 | 4.00 |
| Weibull | $c = 0.9095$, loc $= 0^*$, scale $= 0.1963$ | 2 | $\mathbf{0.2762}$ | $\mathbf{-232.26}$ | $-225.67$ | 0.96 | 1.33 |
| Log-logística | $c = 1.307$, loc $= 0^*$, scale $= 0.1184$ | 2 | 1.143 | $-206.65$ | $-200.06$ | 0.469 | 5.00 |
| Rayleigh | loc $= 0^*$, scale $= 0.2173$ | 1 | 18.12 | 85.99 | 89.29 | $1.24 \times 10^{-21}$ | 9.00 |
| Gumbel | loc $= 0.1171$, scale $= 0.132$ | 2 | 5.729 | $-138.45$ | $-131.85$ | 0.00697 | 7.00 |

### 4.3.3 Conjunto de datos C

Tabla 8: Bondad de ajuste para el conjunto de datos C.

| Distribución | Parámetros | $k$ | SSE | AIC | BIC | KS $p$ | Rango |
|---|---|---|---|---|---|---|---|
| Exponencial | loc $= 0^*$, scale $= 762.4$ | 1 | $5.978 \times 10^{-8}$ | 3056.59 | 3059.88 | 0.0667 | 3.33 |
| Lognormal | $s = 1.648$, loc $= 0^*$, scale $= 324.3$ | 2 | $6.361 \times 10^{-8}$ | 3084.19 | 3090.78 | 0.0222 | 5.67 |
| Normal | loc $= 762.4$, scale $= 920.8$ | 2 | $9.265 \times 10^{-7}$ | 3301.68 | 3308.28 | $8.75 \times 10^{-8}$ | 8.00 |
| Gamma | $a = 0.7062$, loc $= 0^*$, scale $= 1080$ | 2 | $4.493 \times 10^{-8}$ | $\mathbf{3040.22}$ | $\mathbf{3046.82}$ | 0.913 | 1.67 |
| Beta | $a = 0.5847$, $b = 4.109$, loc $= 0^*$, scale $= 6737^*$ | 2 | $1.298 \times 10^{-7}$ | 3061.97 | 3068.57 | 0.19 | 4.67 |
| Weibull | $c = 0.8007$, loc $= 0^*$, scale $= 676$ | 2 | $2.524 \times 10^{-8}$ | 3040.81 | 3047.41 | 0.941 | 1.67 |
| Log-logística | $c = 1.126$, loc $= 0^*$, scale $= 384.4$ | 2 | $4.076 \times 10^{-8}$ | 3072.48 | 3079.08 | 0.263 | 4.00 |
| Rayleigh | loc $= 0^*$, scale $= 845.3$ | 1 | $1.434 \times 10^{-6}$ | 3481.09 | 3484.39 | $6.72 \times 10^{-30}$ | 9.00 |
| Gumbel | loc $= 409.7$, scale $= 515.2$ | 2 | $4.557 \times 10^{-7}$ | 3175.64 | 3182.24 | 0.00322 | 7.00 |

### 4.3.4 Conjunto de datos D

Tabla 9: Bondad de ajuste para el conjunto de datos D.

| Distribución | Parámetros | $k$ | SSE | AIC | BIC | KS $p$ | Rango |
|---|---|---|---|---|---|---|---|
| Exponencial | loc $= 0^*$, scale $= 2.06$ | 1 | 0.009898 | 691.18 | 694.48 | 0.372 | 3.33 |
| Lognormal | $s = 1.019$, loc $= 0^*$, scale $= 1.273$ | 2 | 0.006913 | **675.89** | **682.49** | 0.591 | 1.33 |
| Normal | loc $= 2.06$, scale $= 2.321$ | 2 | 0.1175 | 908.33 | 914.93 | $1.59 \times 10^{-7}$ | 8.00 |
| Gamma | $a = 1.178$, loc $= 0^*$, scale $= 1.749$ | 2 | 0.01048 | 689.97 | 696.56 | 0.427 | 3.67 |
| Beta | $a = 0.8645$, $b = 5.872$, loc $= 0^*$, scale $= 18.15^*$ | 2 | 0.0249 | 739.02 | 745.62 | 0.00403 | 6.00 |
| Weibull | $c = 1.042$, loc $= 0^*$, scale $= 2.099$ | 2 | 0.01066 | 692.55 | 699.14 | 0.352 | 5.00 |
| Log-logística | $c = 1.705$, loc $= 0^*$, scale $= 1.31$ | 2 | **0.006011** | 681.40 | 688.00 | 0.661 | 1.67 |
| Rayleigh | loc $= 0^*$, scale $= 2.194$ | 1 | 0.1572 | 934.06 | 937.36 | $1.09 \times 10^{-18}$ | 9.00 |
| Gumbel | loc $= 1.228$, scale $= 1.216$ | 2 | 0.0487 | 756.07 | 762.67 | 0.0177 | 7.00 |

### 4.3.5 Las tres distribuciones con mejor ajuste

Para escoger las tres mejores de cada conjunto, las distribuciones se ordenaron según su posición promedio en SSE, AIC y BIC. Así se tiene en cuenta tanto el parecido con la forma del histograma (SSE) como el ajuste a todos los datos castigando el número de parámetros (AIC y BIC). Cuando hubo empate se usó el BIC para desempatar. La Tabla 10 resume el resultado. Las Figuras 9 a 12 muestran a la izquierda el histograma con las tres curvas y a la derecha la distribución acumulada de los datos comparada con las de las distribuciones ajustadas; en esta última se nota mejor qué pasa en las colas.

Tabla 10: Las tres distribuciones con mejor ajuste por conjunto de datos.

| Dataset | Posición | Distribución | Parámetros | AIC | BIC |
|---|---|---|---|---|---|
| A | 1 | Normal | $\mu = 0.195$, $\sigma = 0.0437$ | −680.59 | −673.99 |
| | 2 | Weibull | $c = 5.071$, scale $= 0.212$ | −679.36 | −672.76 |
| | 3 | Beta | $a = 5.902$, $b = 3.234$, scale $= 0.302^*$ | −675.74 | −669.14 |
| B | 1 | Weibull | $c = 0.9095$, scale $= 0.1963$ | −232.26 | −225.67 |
| | 2 | Exponencial | scale $= 1/\lambda = 0.2054$ | −231.13 | −227.83 |
| | 3 | Gamma | $a = 0.8636$, scale $= 0.2378$ | −232.10 | −225.50 |
| C | 1 | Gamma | $a = 0.7062$, scale $= 1080$ | 3040.22 | 3046.82 |
| | 2 | Weibull | $c = 0.8007$, scale $= 676.0$ | 3040.81 | 3047.41 |
| | 3 | Exponencial | scale $= 1/\lambda = 762.4$ | 3056.59 | 3059.88 |
| D | 1 | Lognormal | $s = 1.019$, scale $= e^{\mu} = 1.273$ | 675.89 | 682.49 |
| | 2 | Log-logística | $c = 1.705$, scale $= 1.310$ | 681.40 | 688.00 |
| | 3 | Exponencial | scale $= 1/\lambda = 2.060$ | 691.18 | 694.48 |

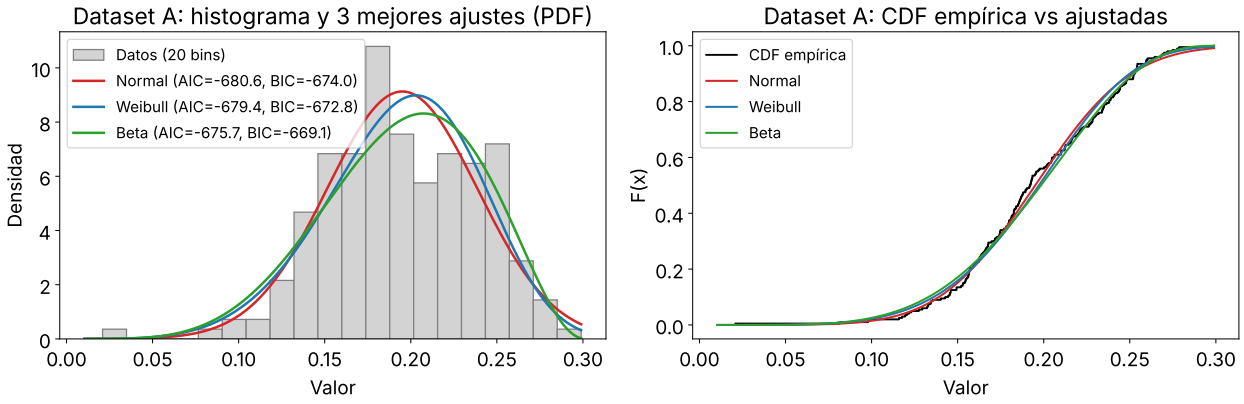



Figura 9: Conjunto A: histograma con las tres distribuciones de mejor ajuste (izq.) y CDF empírica frente a las ajustadas (der.).

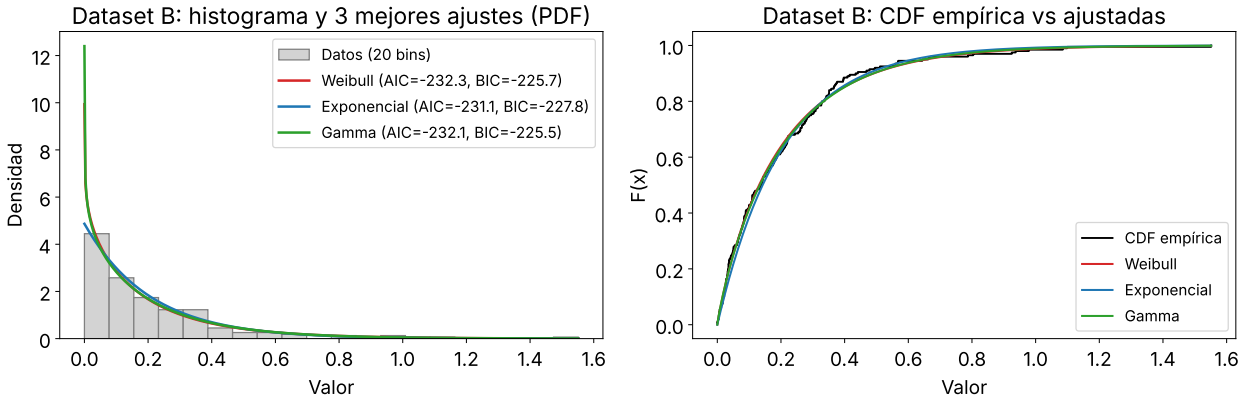



Figura 10: Conjunto B: histograma con las tres distribuciones de mejor ajuste (izq.) y CDF empírica frente a las ajustadas (der.).

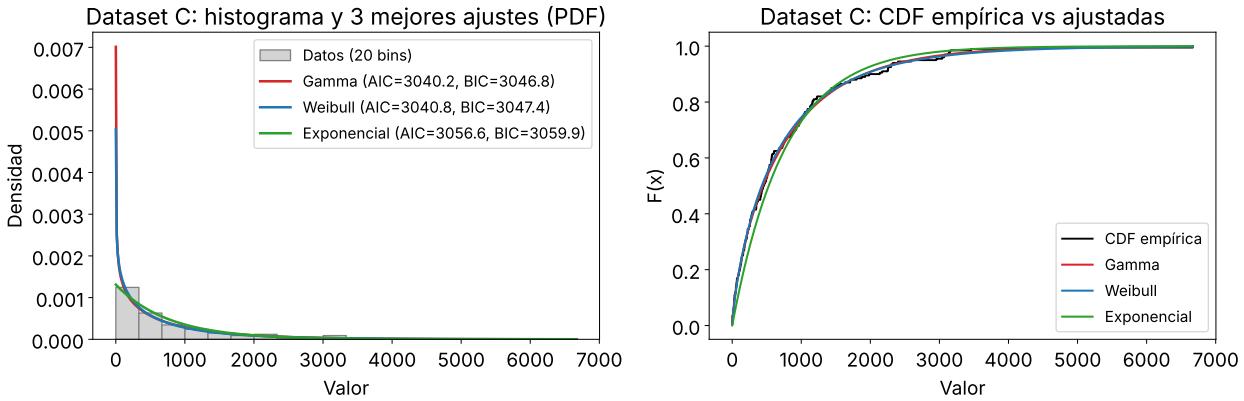



Figura 11: Conjunto C: histograma con las tres distribuciones de mejor ajuste (izq.) y CDF empírica frente a las ajustadas (der.).

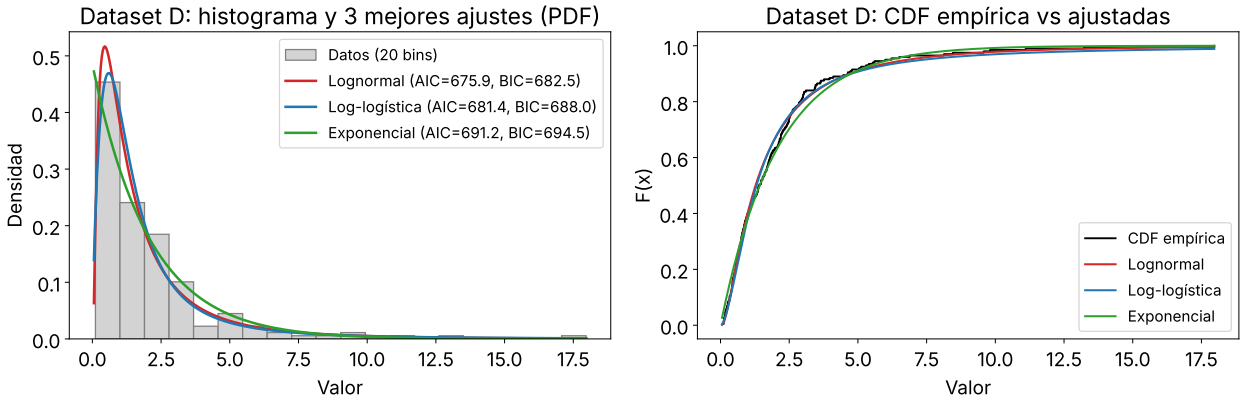



Figura 12: Conjunto D: histograma con las tres distribuciones de mejor ajuste (izq.) y CDF empírica frente a las ajustadas (der.).

Para revisar mejor el ajuste también se hicieron gráficos Q-Q de las tres mejores distribuciones (Figura 13). Si el ajuste es bueno, los puntos quedan sobre la diagonal; cuando se separan en los extremos, la distribución no está representando bien las colas.

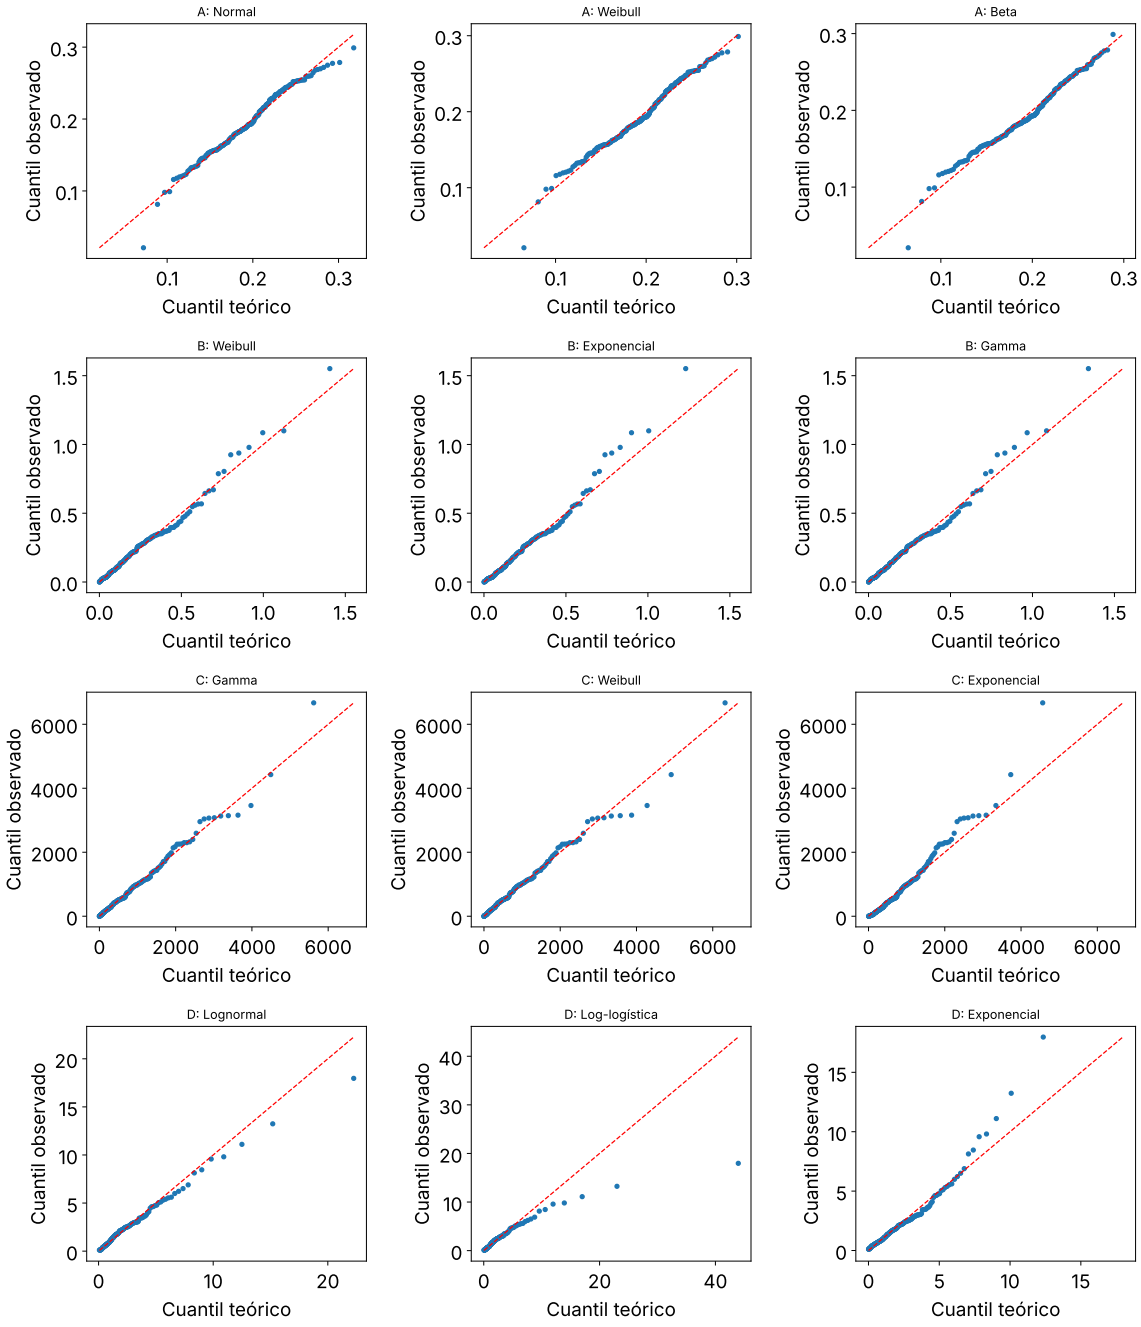



Figura 13: Gráficos Q-Q de las tres distribuciones de mejor ajuste para cada conjunto (filas A, B, C y D).

### 4.3.6 Selección de la distribución para cada conjunto de datos

**Dataset A: Normal,** $N(\mu \approx 0.195,\ \sigma \approx 0.0437)$**.** Es la distribución con menor AIC y BIC de las nueve, y su SSE está muy cerca del mínimo (29.15, contra 28.24 de la gamma). La Weibull (forma 5.07) y la beta quedaron muy cerca, lo cual tiene sentido porque con esos parámetros también tienen forma de campana casi simétrica. Se escogió la normal porque es la más fácil de interpretar, tiene el mejor AIC y BIC y además el valor $p$ de KS más alto (0.63). Es cierto que la normal permite valores negativos, pero aquí la probabilidad de eso es de apenas $P(X < 0) \approx 4 \times 10^{-6}$ (la media está a unas

4.5 desviaciones de cero), así que en la práctica no afecta; si hiciera falta, se puede cortar en 0 al simular. Hay que tener en cuenta que A tiene correlación (sección 5.2), entonces esta normal solo describe cómo se reparten los valores. Si se generan valores independientes con ella, la simulación no va a reproducir la dependencia que se observó.

**Dataset B: Exponencial, scale** $= 1/\lambda \approx 0.205$ **(**$\lambda \approx 4.87$**).** La Weibull (forma 0.91) y la gamma (forma 0.86) tienen un AIC un poco menor y un SSE más bajo, pero su parámetro de forma está cerca de 1, que es justo cuando ambas se vuelven una exponencial. La exponencial tiene el menor BIC, que es el criterio que más castiga los parámetros de más, y la diferencia de AIC con la mejor es de solo 1.1 puntos (diferencias menores que 2 se toman como equivalentes). Además, al tener un solo parámetro es el modelo más simple. Esto encaja con lo visto en 5.1 (CV cercano a 1) y en 5.2 (proceso IID y estacionario, que corresponde a llegadas de Poisson). Si se quisiera representar mejor el pequeño exceso de valores muy cercanos a cero, la Weibull sería la otra opción.

**Dataset C: Weibull, forma** $c \approx 0.80$**, scale** $\approx 676$**.** La Weibull y la gamma quedaron empatadas en la posición promedio, y la gamma aparece de primera solo porque gana el desempate por BIC por 0.6 puntos. Se prefirió la Weibull porque su SSE es bastante menor ($2.5\times10^{-8}$ contra $4.5\times10^{-8}$) y su AIC y BIC son prácticamente iguales a los de la gamma. Las dos superan con buena diferencia a la exponencial ($\Delta$AIC $\approx 16$). Que la forma sea menor que 1 quiere decir que hay más valores pequeños y una cola más larga que en una exponencial. Aun así, en la sección 5.2 se encontró que C no es estacionario, porque los tiempos entre llegadas van creciendo. Con datos así ninguna distribución sola es adecuada para simular el proceso, y la forma menor que 1 de la Weibull aparece precisamente por mezclar datos de momentos con medias muy distintas. Lo recomendable sería modelar la tendencia, por ejemplo con un proceso de Poisson no homogéneo con tasa decreciente o ajustando distribuciones por tramos de tiempo, y usar esta Weibull solo como una aproximación general.

**Dataset D: Lognormal,** $s = \sigma \approx 1.02$**, scale** $= e^{\mu} \approx 1.27$ **(**$\mu \approx 0.24$**).** Es la de menor AIC y BIC. La log-logística quedó de segunda (su SSE es un poco menor, pero su AIC y BIC son 5.5 puntos peores) y la exponencial de tercera ($\Delta$AIC $\approx 15$). La lognormal sigue bien el pico del histograma cerca de 0.5, mientras que la exponencial pone el pico en cero, y también representa bien la cola pesada de los datos (con valores de hasta 18 y asimetría de 3.2). En el gráfico Q-Q se ve que la exponencial se queda corta con los valores grandes y que la log-logística se pasa en la cola extrema. Como D es IID y estacionario (sección 5.2), la lognormal se puede usar directamente en una simulación.

Tabla 11: Resumen de la evaluación de supuestos y de la distribución seleccionada para cada conjunto de datos.

| Dataset | Evaluación de supuestos (5.2) | Distribución seleccionada | Parámetros |
|---|---|---|---|
| A | Estacionario, pero correlacionado (no IID) | Normal | $\mu = 0.195$, $\sigma = 0.0437$ |
| B | IID y estacionario | Exponencial | $1/\lambda = 0.2054$ |
| C | No estacionario (tendencia creciente) | Weibull | $c = 0.8007$, scale $= 676.0$ |
| D | IID y estacionario | Lognormal | $s = 1.019$, scale $= 1.273$ |

# 5 Conclusiones

- Con la estadística descriptiva y los histogramas se pudo tener una primera idea de qué distribuciones probar (una simétrica para A y otras cargadas a la derecha para B, C y D). Sin embargo, con estas herramientas no se alcanza a ver si los datos dependen unos de otros o si cambian con el tiempo.
- Por eso las gráficas de la sección 5.2 fueron necesarias antes de ajustar cualquier distribución. Con ellas se encontró que B y D cumplen el supuesto IID, que A es estacionario pero tiene autocorrelación ($\hat{\rho}_1 \approx 0.5$) y que C tiene una tendencia creciente. En A y C, usar una sola distribución IID es una simplificación y se debe aclarar si se usa en una simulación.
- El SSE, el AIC y el BIC no siempre escogen la misma distribución. El SSE depende de cuántas clases tenga el histograma y solo mira la forma, mientras que el AIC y el BIC usan todos los datos y castigan los parámetros de más. Por eso la decisión final se tomó mirando las tres métricas y prefiriendo modelos simples que tuvieran sentido con el proceso; por ejemplo, en B se escogió la exponencial en vez de una Weibull o una gamma con forma casi igual a 1.
- Fue necesario fijar en cero el parámetro de localización para los datos positivos. Cuando se dejaba libre, el ajuste daba resultados sin sentido en varios casos.
- Al final se escogieron estas distribuciones: Normal para A, Exponencial para B, Weibull para C (teniendo en cuenta que no es estacionario) y Lognormal para D.

# 6 Anexos

Junto con este informe se entrega el siguiente archivo:

- `Lab6_Analisis_datos_entrada_y_bondad_de_ajuste.ipynb`: notebook de Jupyter/Google Colab ya ejecutado, con todo el desarrollo de las secciones 5.1, 5.2 y 5.3. Incluye la estadística descriptiva y los histogramas, las gráficas del análisis de datos de entrada, las pruebas de independencia y de tendencia, el ajuste de las nueve distribuciones con SSE, AIC y BIC, y las gráficas de las tres mejores distribuciones de cada conjunto. Para correrlo se necesitan los archivos `dataset-A.txt`, `dataset-B.txt`, `dataset-C.txt` y `dataset-D.txt` en la misma carpeta; en Colab, el notebook los pide si no los encuentra.

# Referencias

[1] Banks, J. (1998). *Handbook of Simulation: Principles, Methodology, Advances, Applications, and Practice*. John Wiley & Sons, Inc. Capítulo 3.

[2] Amat Rodrigo, J. (2021). *Ajuste y selección de distribuciones con Python*. Disponible con licencia CC BY-NC-SA 4.0 en `https://www.cienciadedatos.net/documentos/pystats01-ajuste-distribuciones-python.html`. `https://doi.org/10.5281/zenodo.10006330`

[3] Virtanen, P. et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261–272. Documentación de `scipy.stats`: `https://docs.scipy.org/doc/scipy/reference/stats.html`