

Universidad de los Llanos
Facultad de Ciencias Básicas e Ingeniería
Ingeniería de Sistemas
Curso: Simulación Computacional

**Práctica Número Dos: Números (pseudo)aleatorios
y Generación de Variables Aleatorias**

Secciones 5.1, 5.2, 5.3 y 5.4

Código del formato: FO-DOC-112

David Andrés Monroy
Código estudiantil: 160005019
Ingeniería de Sistemas – Universidad de los Llanos

3 de septiembre de 2026

Índice

1	Objetivos	1
2	Consulta previa	1
3	Fundamento teórico	3
4	Procedimiento y resultados	3
4.1	5.1. Generación de números (pseudo)aleatorios	3
4.1.1	5.1.1. Método de MidSquare (cuadrados medios)	3
4.1.2	5.1.2. Generador congruencial mixto	4
4.1.3	5.1.3. Otros generadores de números pseudoaleatorios	4
4.1.4	5.1.4. Tamaño de ciclo, pruebas de uniformidad y aleatoriedad	4
4.2	5.2. Uso de números aleatorios para evaluar integrales	6
4.3	5.3. Generación de variables aleatorias discretas	7
4.4	5.4. Simulación Ad Hoc con generadores propios (Poisson y Binomial)	9
4.4.1	Generadores propios de variables aleatorias	9
4.4.2	Simulación con 20 clientes	9
4.4.3	Medidas de desempeño	10
4.4.4	Repetición de la simulación (10 corridas)	11
4.4.5	Intervalos de confianza (95 % y 99 %)	11
4.4.6	Comparación con los resultados de la Práctica 1	12
5	Conclusiones	12
6	Anexos	13

1 Objetivos

- Introducir los métodos de generación y validación de números pseudoaleatorios: MidSquare, generador congruencial mixto y otros generadores (Shift-Register y Lagged-Fibonacci).
- Calcular el tamaño de ciclo o periodo de las secuencias de números pseudoaleatorios generadas, y evaluar si cumplen con los criterios de uniformidad (prueba Chi-cuadrada) y aleatoriedad (prueba de rachas).
- Usar la generación de números pseudoaleatorios uniformes para aproximar, mediante el método de Monte Carlo, el valor de integrales definidas, incluyendo integrales dobles e integrales con límites infinitos.
- Generar variables aleatorias discretas a partir de un generador congruencial mixto, aplicando el método de la transformada inversa y el método de composición.
- Construir generadores propios de variables aleatorias Poisson y Binomial, siguiendo los algoritmos secuencial y recursivo, respectivamente.
- Repetir la simulación de un sistema de cola simple desarrollada en la Práctica 1, sustituyendo la generación de tiempos por dados/ruletas (uniforme discreta) por los generadores propios de Poisson y Binomial construidos en esta práctica.
- Comparar los resultados obtenidos con los generadores propios frente a los obtenidos en la Práctica 1 con distribuciones uniformes discretas.

2 Consulta previa

¿Qué es una variable aleatoria?

Una variable aleatoria es una función que asigna un valor numérico a cada uno de los resultados posibles de un experimento aleatorio. Puede ser discreta, si toma un número finito o numerable de valores (por ejemplo, el número de clientes que llegan en una hora), o continua, si puede tomar cualquier valor dentro de un intervalo (por ejemplo, un tiempo de servicio medido con precisión arbitraria). En simulación, las variables aleatorias se usan para representar la incertidumbre de fenómenos como los tiempos entre llegadas, los tiempos de servicio o el resultado de un número pseudoaleatorio generado por un algoritmo.

¿Qué es una distribución de probabilidad?

Una distribución de probabilidad es una descripción matemática de cómo se reparte la probabilidad entre los distintos valores que puede tomar una variable aleatoria. En el caso discreto, se describe mediante una función de masa de probabilidad $p(x_i) = P(X = x_i)$, que indica la probabilidad de cada valor puntual; en el caso continuo, se describe mediante una función de densidad $f(x)$, tal que la probabilidad de que la variable caiga en un intervalo se obtiene integrando f sobre dicho intervalo. En ambos casos, la distribución debe satisfacer que las probabilidades sean no negativas y que su suma (o integral) total sea igual a 1.

¿Cuál es la diferencia entre una distribución de probabilidad discreta y una distribución de probabilidad continua?

La diferencia principal está en el conjunto de valores que puede tomar la variable aleatoria asociada. En una distribución discreta, la variable toma un número finito o numerable de valores

(por ejemplo, los enteros 1 a 6 al lanzar un dado), y a cada valor puntual se le asocia una probabilidad positiva mediante la función de masa $p(x_i)$. En una distribución continua, la variable puede tomar cualquier valor dentro de un intervalo de números reales, y la probabilidad de que tome exactamente un valor puntual es cero; en su lugar, se trabaja con la función de densidad $f(x)$ y las probabilidades se obtienen integrando dicha densidad sobre un intervalo.

¿Cuál es la definición de la distribución de probabilidad uniforme continua $U(0,1)$?

Es la distribución de una variable aleatoria continua U que toma valores en el intervalo $(0,1)$ con densidad de probabilidad constante en todo el intervalo,

$$f(u) = \begin{cases} 1, & 0 \leq u \leq 1 \\ 0, & \text{en otro caso,} \end{cases}$$

lo que significa que cualquier subintervalo de $(0,1)$ tiene una probabilidad de ocurrencia proporcional únicamente a su longitud, sin que ninguna región del intervalo esté favorecida sobre otra. Esta distribución es la base de todos los generadores de números pseudoaleatorios usados en esta práctica, ya que a partir de ella (mediante transformada inversa, composición u otros métodos) se generan variables aleatorias con distribuciones más complejas.

¿Cuál es la definición de la distribución de probabilidad de Poisson?

La distribución de Poisson con parámetro $\lambda > 0$ modela el número de eventos que ocurren en un intervalo fijo de tiempo o espacio, cuando dichos eventos suceden de manera independiente entre sí a una tasa promedio constante λ . Su función de masa de probabilidad es

$$P(X = i) = e^{-\lambda} \frac{\lambda^i}{i!}, \quad i = 0, 1, 2, \dots,$$

y tanto su media como su varianza son iguales a λ . En esta práctica se usa para modelar el tiempo entre llegadas de los clientes en la sección 5.4.

¿Cuál es la definición de la distribución de probabilidad Binomial?

La distribución Binomial con parámetros n (número de ensayos) y p (probabilidad de éxito en cada ensayo) modela el número de éxitos obtenidos en n ensayos independientes de Bernoulli, cada uno con la misma probabilidad de éxito p . Su función de masa de probabilidad es

$$P(X = i) = \binom{n}{i} p^i (1-p)^{n-i}, \quad i = 0, 1, \dots, n,$$

con media np y varianza $np(1-p)$. En esta práctica se usa para modelar el tiempo de servicio de los clientes en la sección 5.4.

¿A qué se refiere la propiedad de que una variable aleatoria sea independiente e idénticamente distribuida (i.i.d.)?

Se dice que un conjunto de variables aleatorias $X_1, X_2, \dots, X_n$ es independiente e idénticamente distribuido (i.i.d., por sus siglas en inglés) cuando todas provienen de la misma distribución de probabilidad (mismos parámetros y misma forma) y, además, el resultado de cada una no depende ni influye en el resultado de las demás. Esta propiedad es fundamental en simulación: los números pseudoaleatorios generados por un buen generador deben comportarse como una secuencia i.i.d. de variables $U(0,1)$, y las observaciones de las distintas corridas de una simulación se tratan como i.i.d. para poder calcular medias, varianzas e intervalos de confianza válidos.

¿En qué consiste una prueba o test estadístico?

Una prueba o test estadístico es un procedimiento formal para decidir, a partir de una muestra de datos, si se puede rechazar o no una hipótesis (llamada hipótesis nula, H_0) acerca de una población o de un proceso generador de datos. El procedimiento consiste en calcular, a partir de la muestra, un estadístico de prueba cuya distribución se conoce bajo el supuesto de que H_0 es cierta; luego se compara ese estadístico contra un valor crítico (o se calcula un valor p) asociado a un nivel de significancia α elegido de antemano. Si el estadístico calculado cae en la región crítica (o el valor p es menor que α), se rechaza H_0 ; en caso contrario, no hay evidencia suficiente para rechazarla. En esta práctica se usan dos pruebas de este tipo sobre las secuencias de números pseudoaleatorios generadas en la sección 5.1: la prueba de Chi-cuadrada (para evaluar uniformidad) y la prueba de rachas arriba/abajo de la media (para evaluar aleatoriedad/independencia).

3 Fundamento teórico

El desarrollo de esta práctica se apoya en el Capítulo 3 (*Generation of random variables*) y el Capítulo 4 (*Generation of discrete random variables*) del texto de Ross [1], así como en el Capítulo 1 de *Handbook of Simulation* [2], particularmente en la sección 1.11.1 (*Statistical Confidence and Run Length*) para el cálculo de los intervalos de confianza.

La sección 5.1 desarrolla la generación y validación de números pseudoaleatorios (sección 3.1 de [1]): el método de MidSquare, el generador congruencial mixto y otros generadores (Shift-Register y Lagged-Fibonacci), evaluando para cada secuencia su tamaño de ciclo y las pruebas de uniformidad (Chi-cuadrada) y aleatoriedad (rachas). La sección 5.2 desarrolla el uso de números aleatorios para aproximar integrales por el método de Monte Carlo, incluyendo integrales dobles y con límites infinitos. La sección 5.3 desarrolla la generación de variables aleatorias discretas mediante el método de la transformada inversa y el método de composición, usando como fuente de números pseudoaleatorios un generador congruencial mixto con parámetros $X_0 = 2391$, $a = 25214903917$, $c = 11$ y $m = 2^{48}$, indicados en la guía. Finalmente, la sección 5.4 retoma el caso ad hoc de la simulación de una cola de un solo servidor desarrollado en la Práctica 1, sustituyendo los generadores basados en dados/ruletas (uniforme discreta) por generadores propios de una variable Poisson (para los tiempos entre llegadas) y una variable Binomial (para los tiempos de servicio).

4 Procedimiento y resultados

4.1 5.1. Generación de números (pseudo)aleatorios

4.1.1 5.1.1. Método de MidSquare (cuadrados medios)

Se implementó el generador de MidSquare, que a partir de una semilla de d dígitos eleva el valor actual al cuadrado, rellena el resultado con ceros a la izquierda hasta $2d$ dígitos y extrae los d dígitos centrales como el siguiente término de la secuencia; dividiendo ese valor entre 10^d se obtiene el número pseudoaleatorio u_i en $(0, 1)$. Se generaron $n = 100$ valores para cada una de las cinco semillas indicadas en la guía: 1931, 675248, 4567, 12122 y 7179345.

Observación. Con la semilla 1931 la secuencia degenera rápidamente hacia cero (a partir de $i = 7$ todos los valores son 0.0000), ya que al elevar al cuadrado un número cuyos dígitos centrales son pequeños, el resultado tiende a perder cifras significativas hasta anclarse en 0. Este comportamiento degenerativo es una de las debilidades clásicas del método de MidSquare, que se confirma más adelante con las pruebas de periodo, uniformidad y aleatoriedad.

Tabla 1: MidSquare – primeros valores generados por semilla

i	Semilla 1931	Semilla 675248	Semilla 4567	Semilla 12122	Semilla 7179345
1	0.7287	0.959861	0.8574	0.46942	0.4299462
2	0.1003	0.333139	0.5134	0.03551	0.8537348
3	0.0060	0.981593	0.3579	0.12609	0.8631087
4	0.0036	0.524817	0.8092	0.58986	0.9566280
5	0.0012	0.432883	0.4804	0.79348	0.1371303
6	0.0001	0.387691	0.0784	0.96105	0.8047191
7	0.0000	0.304311	0.6146	0.36171	0.5728299
8	0.0000	0.605184	0.7733	0.08341	0.1340943
9	0.0000	0.247673	0.7992	0.69572	0.9812812
10	0.0000	0.341914	0.8720	0.40263	0.9127934

4.1.2 5.1.2. Generador congruencial mixto

Se implementó el generador congruencial lineal mixto (GLC), definido por la recursión $X_{n+1} = (aX_n + c) \bmod m$, $U_n = X_n/m$, y se generaron $n = 100$ valores para los cinco juegos de parámetros indicados en la guía.

Tabla 2: Generador congruencial mixto – parámetros usados y primeros valores U_i obtenidos

Generador	Parámetros	U_1	U_2	U_3
LCG 1	$X_0 = 127, a = 115, c = 0, m = 128$	0.1016	0.6797	0.1641
LCG 2	$X_0 = 43, a = 25, c = 5, m = 48$	0.5000	0.6042	0.2083
LCG 3	$X_0 = 13, a = 16807, c = 0, m = 2^{31} - 1$	0.0001	0.7100	0.8229
LCG 4	$X_0 = 29022024, a = 25214903917, c = 11, m = 2^{48}$	0.8316	0.5264	0.5038
LCG 5	$X_0 = 3, a = 5, c = 7, m = 200$	0.1100	0.5850	0.9600

4.1.3 5.1.3. Otros generadores de números pseudoaleatorios

Siguiendo la lectura del artículo de Mancilla [3], se implementaron dos generadores adicionales:

Shift-Register (registro de desplazamiento): a partir de una semilla de 31 bits, cada nuevo bit se calcula como la suma módulo 2 (XOR) de un subconjunto fijo de bits anteriores (*taps*), en este caso las posiciones 31 y 3. Empaquetando bloques de 31 bits consecutivos y dividiendo entre 2^{31} se obtiene cada número pseudoaleatorio $u_i \in (0, 1)$.

Lagged-Fibonacci: a partir de una tabla semilla de 7 valores, cada nuevo término se calcula como $X_i = (X_{i-j} \text{ op } X_{i-k}) \bmod M$, con $j = 3, k = 7, M = 2^{31}$ y la operación de suma; dividiendo entre M se obtiene u_i .

4.1.4 5.1.4. Tamaño de ciclo, pruebas de uniformidad y aleatoriedad

Para cada una de las secuencias generadas en 5.1.1, 5.1.2 y 5.1.3 se calcularon tres indicadores:

Tabla 3: Shift-Register y Lagged-Fibonacci – primeros valores generados

i	Shift-Register	Lagged-Fibonacci
1	0.0664	0.2648
2	0.3576	0.3797
3	0.3192	0.4947
4	0.6449	0.9546
5	0.0222	0.1271
6	0.8687	0.2996
7	0.3320	0.8170
8	0.8021	0.3919
9	0.7269	0.6793
10	0.3128	0.3117

- **Periodo o ciclo:** se busca la primera repetición de un valor ya generado; el periodo es la distancia entre esa repetición y su primera aparición. Si no se detecta ninguna repetición dentro de las 100 observaciones generadas, se reporta como “> 100” (el periodo real es mayor o igual a 100).
- **Prueba de uniformidad (Chi-cuadrada):** se divide el intervalo $[0, 1)$ en $k = 10$ subintervalos, se compara la frecuencia observada O_i contra la esperada $E_i = n/k$, y se calcula $\chi^2 = \sum (O_i - E_i)^2 / E_i$, comparándolo contra el valor crítico $\chi_{k-1, 1-\alpha}^2$ con $\alpha = 0.05$.
- **Prueba de aleatoriedad (rachas arriba/abajo de la media):** se codifica cada u_i como “+” si está por encima de la media (0.5) o “-” si está por debajo, se cuenta el número de rachas R y se calcula el estadístico $Z = (R - \mu_R) / \sigma_R$, comparándolo contra el valor crítico normal $Z_{1-\alpha/2}$ con $\alpha = 0.05$.

Tabla 4: MidSquare – periodo, uniformidad y aleatoriedad

Semilla	Periodo	χ^2 calc.	χ^2 crít.	$\hat{u}$ Uniforme?	Z rachas	Z crít.	$\hat{u}$ Aleatoria?
1931	1	860.6	16.919	Se rechaza H_0 (NO uniforme)	-8.587	1.96	Se rechaza H_0 (NO aleatoria)
675248	> 100	12.4	16.919	No se rechaza H_0 (uniforme)	1.608	1.96	No se rechaza H_0 (aleatoria)
4567	4	109.4	16.919	Se rechaza H_0 (NO uniforme)	-0.402	1.96	No se rechaza H_0 (aleatoria)
12122	1	52.2	16.919	Se rechaza H_0 (NO uniforme)	-3.407	1.96	Se rechaza H_0 (NO aleatoria)
7179345	> 100	15.0	16.919	No se rechaza H_0 (uniforme)	-1.149	1.96	No se rechaza H_0 (aleatoria)

Tabla 5: Generador congruencial mixto – periodo, uniformidad y aleatoriedad

Gen.	Parámetros	Periodo	χ^2 calc.	$\hat{u}$ Uniforme?	Z rachas	$\hat{u}$ Aleatoria?
LCG 1	$a=115, c=0, m=128, X_0=127$	32	6.8	No se rechaza (uniforme)	-1.005	No se rechaza (aleatoria)
LCG 2	$a=25, c=5, m=48, X_0=43$	48	1.2	No se rechaza (uniforme)	-1.005	No se rechaza (aleatoria)
LCG 3	$a=16807, c=0, m=2^{31}-1, X_0=13$	> 100	12.0	No se rechaza (uniforme)	0.440	No se rechaza (aleatoria)
LCG 4	$a=25214903917, c=11, m=2^{48}, X_0=29022024$	> 100	4.8	No se rechaza (uniforme)	0.217	No se rechaza (aleatoria)
LCG 5	$a=5, c=7, m=200, X_0=3$	8	22.8	Se rechaza (NO uniforme)	-5.023	Se rechaza (NO aleatoria)

Nota: para las cinco filas, χ^2 crítico = 16.919 y Z crítico = 1.96 (mismos valores de referencia que en la tabla anterior).

Tabla 6: Shift-Register y Lagged-Fibonacci – periodo, uniformidad y aleatoriedad

Generador	Periodo	χ^2 calc.	χ^2 crít.	¿Uniforme?	Z rachas	Z crít.	¿Aleatoria?
Shift-Register	> 100	6.0	16.919	No se rechaza H_0 (uniforme)	0.419	1.96	No se rechaza H_0 (aleatoria)
Lagged-Fibonacci	> 100	6.8	16.919	No se rechaza H_0 (uniforme)	-0.789	1.96	No se rechaza H_0 (aleatoria)

¿Cuáles son los peores generadores de números aleatorios y por qué?

El peor generador es MidSquare: tres de sus cinco semillas (1931, 4567 y 12122) muestran periodos muy cortos (1, 4 y 8, respectivamente), lo que significa que la secuencia comienza a repetirse casi de inmediato, degenerando incluso hacia cero en el caso de la semilla 1931. Esas mismas semillas fallan la prueba de uniformidad (“se rechaza H_0 ”) y, en dos de los tres casos, también la prueba de aleatoriedad, con estadísticos χ^2 y Z muy alejados de sus valores críticos (por ejemplo, $\chi^2 = 860.6$ frente a un crítico de apenas 16.919 en la semilla 1931). Dentro de los generadores congruenciales, el LCG 5 ($a = 5, c = 7, m = 200, X_0 = 3$) también se comporta mal, con un periodo corto (8) y rechazo de ambas pruebas, lo cual es consistente con su módulo pequeño ($m = 200$) y una elección de parámetros que no garantiza periodo completo.

¿Cuáles son los mejores generadores de números aleatorios y por qué?

1. **LCG 4** ($a = 25214903917, c = 11, m = 2^{48}, X_0 = 29022024$). Es el generador más robusto de los analizados: no se rechaza ni la prueba de uniformidad ni la de aleatoriedad, y su periodo es mayor a las 100 iteraciones evaluadas. Su módulo extremadamente grande ($m = 2^{48}$) garantiza en la práctica un periodo real inmenso, lo que lo hace adecuado para simulaciones que requieran secuencias largas de números de buena calidad estadística.
2. **Shift-Register**. También pasa ambas pruebas (uniformidad y aleatoriedad) con un periodo mayor a 100. Los generadores de registro de desplazamiento son conocidos por producir secuencias con buenas propiedades estadísticas y periodos largos, siempre que la configuración de bits y los *taps* se elijan adecuadamente, como ocurrió en este caso.

4.2 5.2. Uso de números aleatorios para evaluar integrales

Para cada uno de los ejercicios 3 a 9 del Capítulo 3 de [1] se implementó un estimador Monte Carlo genérico, generando $n = 100,000$ números pseudoaleatorios uniformes por estimación (o $n = 200,000$ en el caso de las integrales dobles). Cuando el límite de integración era infinito se aplicó la sustitución $y = 1/(1+x)$ descrita en la Consulta previa.

Ejercicio 3

$$\int_0^1 \exp\{e^x\} dx \approx 6.299839$$

Ejercicio 4

$$\int_0^1 (1-x^2)^{3/2} dx \approx 0.590955 \quad (\text{valor analítico } 3\pi/16 = 0.589049)$$

Ejercicio 5

$$\int_{-2}^2 e^{x+x^2} dx \approx 92.978184$$

Ejercicio 6

$$\int_0^\infty x(1+x^2)^{-2} dx \approx 0.500928 \quad (\text{valor analítico } 1/2 = 0.500000)$$

Ejercicio 7

$$\int_{-\infty}^\infty e^{-x^2} dx \approx 1.767204 \quad (\text{valor analítico } \sqrt{\pi} = 1.772454)$$

Ejercicio 8

$$\int_0^1 \int_0^1 e^{(x+y)^2} dy dx \approx 4.902697$$

Ejercicio 9

$$\int_0^\infty \int_0^x e^{-(x+y)} dy dx \approx 0.500137$$

Tabla 7: Resumen de las estimaciones Monte Carlo – sección 5.2

Ejercicio	Integral	Estimación Monte Carlo
3	$\int_0^1 \exp\{e^x\} dx$	6.299839
4	$\int_0^1 (1-x^2)^{3/2} dx$	0.590955
5	$\int_{-2}^2 e^{x+x^2} dx$	92.978184
6	$\int_0^\infty x(1+x^2)^{-2} dx$	0.500928
7	$\int_{-\infty}^\infty e^{-x^2} dx$	1.767204
8	$\int_0^1 \int_0^1 e^{(x+y)^2} dy dx$	4.902697
9	$\int_0^\infty \int_0^x e^{-(x+y)} dy dx$	0.500137

Análisis. En los ejercicios en los que se cuenta con un valor analítico de referencia (4, 6 y 7), la estimación Monte Carlo se aproxima adecuadamente al valor teórico, con errores relativos pequeños (por ejemplo, 0.32 % en el Ejercicio 6 y 0.30 % en el Ejercicio 7), lo que confirma que $n = 100,000$ números pseudoaleatorios es suficiente para obtener una buena precisión en integrales de este tipo.

4.3 5.3. Generación de variables aleatorias discretas

Para toda la sección se usó el generador congruencial mixto (GLC) con los parámetros indicados en la guía: $X_0 = 2391$, $a = 25214903917$, $c = 11$, $m = 2^{48}$.

5.3.a. $p_1 = 0.20$, $p_2 = 0.15$, $p_3 = 0.25$, $p_4 = 0.40$

Se generaron 100 valores de $X \in \{1, 2, 3, 4\}$ por transformada inversa. Los primeros 20 valores obtenidos fueron: 2 4 4 4 4 3 4 4 3 4 2 1 4 4 1 1 1 1 2 3.

Tabla 8: 5.3.a – Frecuencias observadas vs. teóricas ($n = 100$)

x	Probabilidad teórica	Frecuencia observada
1	0.20	0.21
2	0.15	0.14
3	0.25	0.27
4	0.40	0.38

5.3.b. $P(X = 1) = 0.30$, $P(X = 2) = 0.20$, $P(X = 3) = 0.35$, $P(X = 4) = 0.15$

Los primeros 20 valores generados fueron: 1 3 3 3 3 2 3 4 2 3 2 1 3 3 1 1 1 1 1 2.

Tabla 9: 5.3.b – Frecuencias observadas vs. teóricas ($n = 100$)

x	Probabilidad teórica	Frecuencia observada
1	0.30	0.32
2	0.20	0.22
3	0.35	0.29
4	0.15	0.17

5.3.c. $p_1 = 1/3$, $p_2 = 2/3$

Se generó la variable con $n = 100$, $n = 1,000$ y $n = 10,000$, calculando en cada caso la proporción de valores iguales a 1 (valor teórico esperado: $1/3 = 0.3333$).

Tabla 10: 5.3.c – Proporción muestral de $X = 1$ según el tamaño de muestra

n	Proporción de $X = 1$	Valor teórico
100	0.3400	0.3333
1000	0.3280	0.3333
10 000	0.3316	0.3333

Observación. A medida que n aumenta, la proporción muestral de valores iguales a 1 converge hacia el valor teórico $p_1 = 1/3$, ilustrando la Ley de los Grandes Números.

5.3.d. Método de composición

$X \in \{1, \dots, 10\}$ con probabilidades 0.06, 0.06, 0.06, 0.06, 0.06, 0.15, 0.13, 0.14, 0.15, 0.13. Se descompuso $p_j = \alpha q_j + (1 - \alpha) r_j$ con $\alpha = 0.6$, $q_j = 1/10$ para $j = 1, \dots, 10$, y r_j definida solo sobre

$\{6, \dots, 10\}$:

$$r_6 = 0.225, r_7 = 0.175, r_8 = 0.200, r_9 = 0.225, r_{10} = 0.175 \quad (\sum r_j = 1.000).$$

Los primeros 20 valores generados fueron: 8 9 7 10 8 1 9 2 2 5 8 4 10 10 6 7 7 7 6 9.

Tabla 11: 5.3.d – Frecuencias observadas vs. teóricas ($n = 100$)

x	Probabilidad teórica	Frecuencia observada
1	0.06	0.09
2	0.06	0.06
3	0.06	0.00
4	0.06	0.12
5	0.06	0.09
6	0.15	0.15
7	0.13	0.17
8	0.14	0.13
9	0.15	0.07
10	0.13	0.12

Análisis. En los cuatro literales, las frecuencias observadas con $n = 100$ se aproximan razonablemente a las probabilidades teóricas, aunque con las diferencias esperadas propias de una muestra de tamaño moderado; el literal 5.3.c confirma explícitamente que dichas diferencias se reducen a medida que crece el tamaño de la muestra.

4.4 5.4. Simulación Ad Hoc con generadores propios (Poisson y Binomial)

4.4.1 Generadores propios de variables aleatorias

Se implementaron los algoritmos descritos en la Consulta previa para $\text{Poisson}(\lambda)$ y $\text{Binomial}(n, p)$. Como verificación, se generaron 20 000 realizaciones de cada uno con $\lambda = 10$ y $(n, p) = (10, 0.40)$, obteniendo:

Tabla 12: Verificación de los generadores propios ($n = 20,000$ realizaciones)

Variable	Media empírica	Media teórica
$\text{Poisson}(\lambda = 10)$	10.0286	10.0
$\text{Binomial}(n = 10, p = 0.40)$	3.9874	4.0

Ambas medias empíricas son muy cercanas a las teóricas, lo que valida el correcto funcionamiento de los dos generadores propios antes de emplearlos en la simulación de la cola.

4.4.2 Simulación con 20 clientes

Se repitió la lógica de simulación de la Práctica 1: el primer cliente llega en $t = 0$ sin tiempo entre llegadas; para los siguientes, el tiempo entre llegadas se genera con el Poisson propio ($\lambda = 10$) y

el tiempo de servicio con el Binomial propio ($n = 10, p = 0.40$). La Tabla 13 muestra la corrida obtenida con semilla 1.

Tabla 13: Simulación Ad Hoc – 20 clientes (Poisson/Binomial propios)

Cliente	Tiempo entre llegadas	Hora de llegada	Tiempo de servicio	Inicio de servicio	Fin de servicio	Tiempo en el sistema	Tiempo ocioso	Tiempo en cola
1	–	0	0	0	0	0	0	0
2	11	11	4	11	15	4	11	0
3	7	18	2	18	20	2	3	0
4	9	27	4	27	31	4	7	0
5	5	32	5	32	37	5	1	0
6	10	42	3	42	45	3	5	0
7	10	52	3	52	55	3	7	0
8	8	60	3	60	63	3	5	0
9	4	64	7	64	71	7	1	0
10	13	77	5	77	82	5	6	0
11	8	85	4	85	89	4	3	0
12	11	96	4	96	100	4	7	0
13	6	102	2	102	104	2	2	0
14	7	109	6	109	115	6	5	0
15	9	118	3	118	121	3	3	0
16	8	126	3	126	129	3	5	0
17	10	136	7	136	143	7	7	0
18	7	143	2	143	145	2	0	0
19	15	158	6	158	164	6	13	0
20	12	170	4	170	174	4	6	0

4.4.3 Medidas de desempeño

Tabla 14: Medidas de desempeño – simulación de 20 clientes (Poisson/Binomial propios)

Medida de desempeño	Valor
Tiempo promedio en el sistema	3.8500
Porcentaje de tiempo ocioso	0.5575
Tiempo de espera promedio por cliente	0.0000
Fracción de clientes que esperó	0.0000
Tiempo de espera promedio de quienes esperaron	0.0000

Interpretación. En esta corrida en particular ningún cliente tuvo que esperar en cola (las cinco columnas relacionadas con la espera son cero), lo que se explica porque el tiempo promedio entre llegadas (Poisson con media 10) es notablemente mayor que el tiempo promedio de servicio (Binomial con media 4): en la mayoría de los casos el servidor ya había terminado de atender al cliente anterior antes de que llegara el siguiente. En consecuencia, el porcentaje de tiempo ocioso

del servidor es alto (55.75 %).

4.4.4 Repetición de la simulación (10 corridas)

Siguiendo el mismo esquema de la Práctica 1, se repitió el procedimiento 10 veces, cambiando la semilla del generador en cada corrida. Los resultados se presentan en la Tabla 15.

Tabla 15: Resultados de las 10 corridas – 20 clientes (Poisson/Binomial propios)

Corrida	Tiempo prom. en sistema	% tiempo ocioso	Espera prom. por cliente	Fracción que esperó	Espera prom. de quienes esperaron
1	4.20	0.5692	0.000	0.000	0.000
2	4.25	0.5829	0.100	0.050	2.000
3	3.75	0.6250	0.000	0.000	0.000
4	3.90	0.6100	0.000	0.000	0.000
5	3.55	0.6302	0.000	0.000	0.000
6	4.15	0.5598	0.100	0.050	2.000
7	3.90	0.6100	0.000	0.000	0.000
8	4.30	0.5779	0.100	0.050	2.000
9	3.30	0.6827	0.000	0.000	0.000
10	3.40	0.6059	0.050	0.050	1.000
Media	3.870	0.6054	0.035	0.020	0.700

Análisis. A diferencia de la Práctica 1, en la que la fracción de clientes que esperaba oscilaba entre 0.10 y 0.40, en esta práctica dicha fracción es mucho menor (entre 0.00 y 0.05 en las 10 corridas), y en cinco de las diez corridas ningún cliente tuvo que esperar. Esto confirma, de manera consistente entre corridas, que las distribuciones Poisson y Binomial empleadas producen un sistema con mucha menor congestión que el de la Práctica 1.

4.4.5 Intervalos de confianza (95 % y 99 %)

Para cada medida de desempeño se calculó la media muestral $\bar{X}$, la desviación estándar muestral S , la media anchura $h = t_{n-1, 1-\alpha/2} S/\sqrt{n}$ y el intervalo $[\bar{X} - h, \bar{X} + h]$, con $n = 10$ corridas. Los resultados se muestran en la Tabla 16.

Análisis. En las medidas relacionadas con la espera en cola (espera promedio por cliente, fracción que esperó y espera promedio de quienes esperaron), el intervalo de confianza al 99 % incluye valores negativos en su límite inferior, lo cual es una consecuencia esperable de que la variable subyacente esté acotada por debajo en cero y de que la mayoría de las corridas hayan arrojado valores muy cercanos a cero: al tratarse de una aproximación basada en la distribución t de Student (que asume simetría), el intervalo puede extenderse por debajo del rango posible de la medida. En la práctica, estos límites negativos se interpretan simplemente como que el verdadero promedio poblacional podría estar arbitrariamente cerca de cero.

Tabla 16: Intervalos de confianza 95 % y 99 % – simulación de 20 clientes con Poisson/Binomial (10 corridas)

Medida	Conf.	$\bar{X}$	S	$t_{n-1, 1-\alpha/2}$	h	IC inf.	IC sup.
Tiempo prom. en el sistema	95 %	3.8700	0.3622	2.2622	0.2591	3.6109	4.1291
Tiempo prom. en el sistema	99 %	3.8700	0.3622	3.2498	0.3723	3.4977	4.2423
% tiempo ocioso	95 %	0.6054	0.0360	2.2622	0.0258	0.5796	0.6311
% tiempo ocioso	99 %	0.6054	0.0360	3.2498	0.0370	0.5684	0.6424
Espera prom. por cliente	95 %	0.0350	0.0474	2.2622	0.0339	0.0011	0.0689
Espera prom. por cliente	99 %	0.0350	0.0474	3.2498	0.0487	-0.0137	0.0837
Fracción que esperó	95 %	0.0200	0.0258	2.2622	0.0185	0.0015	0.0385
Fracción que esperó	99 %	0.0200	0.0258	3.2498	0.0265	-0.0065	0.0465
Espera prom. de quienes esperaron	95 %	0.7000	0.9487	2.2622	0.6786	0.0214	1.3786
Espera prom. de quienes esperaron	99 %	0.7000	0.9487	3.2498	0.9750	-0.2750	1.6750

4.4.6 Comparación con los resultados de la Práctica 1

En la Práctica 1, los tiempos entre llegadas se generaron con una uniforme discreta $U\{1, 10\}$ (media 5.5) y los tiempos de servicio con una uniforme discreta $U\{1, 6\}$ (media 3.5). En esta práctica se usan Poisson($\lambda = 10$) (media 10) para las llegadas y Binomial($n = 10, p = 0.4$) (media 4) para el servicio.

Tabla 17: Comparación de medidas de desempeño promedio – 20 clientes

Medida de desempeño	Práctica 1 (uniforme)	Práctica 2 (Poisson/Binomial)
Tiempo promedio en el sistema	4.470	3.870
Porcentaje de tiempo ocioso	0.358	0.605
Tiempo de espera promedio por cliente	0.930	0.035
Fracción de clientes que esperó	0.295	0.020
Tiempo de espera promedio de quienes esperaron	3.006	0.700

Análisis. Como se anticipó, el mayor espaciamiento entre llegadas (media 10 frente a 5.5) se traduce en un porcentaje de tiempo ocioso considerablemente mayor (60.5 % frente a 35.8 %) y en una reducción muy marcada de las medidas relacionadas con la espera: la fracción de clientes que esperó cae de 0.295 a 0.020, y el tiempo de espera promedio de quienes sí esperaron baja de 3.006 a 0.700 minutos. Esto confirma que, aun manteniendo el mismo tipo de sistema (cola con un solo servidor) y el mismo número de clientes por corrida, la elección de la distribución de los tiempos entre llegadas y de servicio tiene un efecto determinante sobre el nivel de congestión observado.

5 Conclusiones

- El método de Monte Carlo permite aproximar con buena precisión integrales definidas, incluso integrales dobles y con límites infinitos, siempre que se use un número suficientemente grande de números pseudoaleatorios y, en el caso de límites infinitos, el cambio de variable adecuado.

- El método de la transformada inversa y el método de composición son dos formas equivalentes, aunque con distinta complejidad de implementación, de generar variables aleatorias discretas a partir de números pseudoaleatorios uniformes; el método de composición resulta particularmente útil cuando la distribución original se puede descomponer en distribuciones más simples de simular.
- Los generadores propios de Poisson y Binomial, implementados con los algoritmos secuencial y recursivo del Capítulo 4 de Ross, reproducen adecuadamente las medias teóricas de dichas distribuciones al evaluarlos sobre una muestra grande.
- Al sustituir, en la simulación de la cola, la distribución uniforme discreta de la Práctica 1 por las distribuciones Poisson y Binomial de esta práctica, el sistema resultó considerablemente menos congestionado: mayor porcentaje de tiempo ocioso del servidor y una fracción mucho menor de clientes que debieron esperar. Esto ilustra que las medidas de desempeño de un sistema de colas dependen críticamente de la forma y los parámetros de las distribuciones que gobiernan los tiempos entre llegadas y de servicio, y no únicamente de sus valores promedio.
- Como en la Práctica 1, una sola corrida de la simulación no es suficiente para caracterizar el sistema: fue necesario repetir la simulación 10 veces y calcular intervalos de confianza para tener una estimación confiable de cada medida de desempeño.

6 Anexos

Junto con este informe se entrega el siguiente archivo:

- `Lab2_160005019.ipynb` – notebook de Jupyter/Google Colab con la implementación completa de las secciones 5.1, 5.2, 5.3 y 5.4, incluyendo los generadores de números pseudoaleatorios y sus pruebas de periodo, uniformidad y aleatoriedad, los generadores propios de Poisson y Binomial, la simulación de la cola y el cálculo de los intervalos de confianza.

Referencias

- [1] Ross, S. M. (1999). *Simulation* (2nd ed.). Academic Press.
- [2] Banks, J. (1998). *Handbook of Simulation: Principles, Methodology, Advances, Applications, and Practice*. John Wiley & Sons, Inc.
- [3] Mancilla Herrera, A. M. (2000). Números aleatorios. Historia, teoría y aplicaciones. *Ingeniería y Desarrollo*, núm. 8, pp. 49–69. Universidad del Norte, Barranquilla, Colombia.