

Universidad de los Llanos
Facultad de Ciencias Básicas e Ingeniería
Ingeniería de Sistemas
Curso: Simulación Computacional

**Práctica Número Dos: Números (pseudo)aleatorios
y Generación de Variables Aleatorias**

Secciones 5.2, 5.3 y 5.4

Código del formato: FO-DOC-112

David Andrés Monroy
Código estudiantil: 160005019
Ingeniería de Sistemas – Universidad de los Llanos

3 de septiembre de 2026

Índice

1	Objetivos	1
2	Consulta previa	1
3	Fundamento teórico	3
4	Procedimiento y resultados	3
4.1	5.2. Uso de números aleatorios para evaluar integrales	3
4.2	5.3. Generación de variables aleatorias discretas	4
4.3	5.4. Simulación Ad Hoc con generadores propios (Poisson y Binomial)	6
4.3.1	Generadores propios de variables aleatorias	6
4.3.2	Simulación con 20 clientes	6
4.3.3	Medidas de desempeño	7
4.3.4	Repetición de la simulación (10 corridas)	8
4.3.5	Intervalos de confianza (95 % y 99 %)	8
4.3.6	Comparación con los resultados de la Práctica 1	8
5	Conclusiones	9
6	Anexos	10

1 Objetivos

- Usar la generación de números pseudoaleatorios uniformes para aproximar, mediante el método de Monte Carlo, el valor de integrales definidas, incluyendo integrales dobles e integrales con límites infinitos.
- Generar variables aleatorias discretas a partir de un generador congruencial mixto, aplicando el método de la transformada inversa y el método de composición.
- Construir generadores propios de variables aleatorias Poisson y Binomial, siguiendo los algoritmos secuencial y recursivo, respectivamente.
- Repetir la simulación de un sistema de cola simple desarrollada en la Práctica 1, sustituyendo la generación de tiempos por dados/ruletas (uniforme discreta) por los generadores propios de Poisson y Binomial construidos en esta práctica.
- Comparar los resultados obtenidos con los generadores propios frente a los obtenidos en la Práctica 1 con distribuciones uniformes discretas.

2 Consulta previa

¿En qué consiste el método de Monte Carlo para aproximar integrales?

El método de Monte Carlo aprovecha que una integral definida se puede interpretar como el valor esperado de la función integrando, evaluada en una variable aleatoria uniforme sobre el intervalo de integración, multiplicado por la longitud de dicho intervalo. Formalmente, si $\theta = \int_a^b g(x) dx$, entonces

$$\theta = (b - a) \cdot E[g(U)], \quad U \sim \text{Unif}(a, b),$$

por lo cual θ se puede estimar generando n valores $U_1, \dots, U_n$ uniformes en (a, b) y calculando

$$\hat{\theta} = (b - a) \cdot \frac{1}{n} \sum_{i=1}^n g(U_i).$$

El mismo principio se extiende a integrales dobles, generando pares de números aleatorios independientes y promediando la función evaluada sobre el área o el dominio correspondiente.

¿Cómo se manejan las integrales con límites infinitos?

Cuando alguno de los límites de integración es infinito, no es posible generar números aleatorios uniformes directamente sobre ese intervalo. Por ello se aplica un cambio de variable que transforma el intervalo infinito en el intervalo $(0, 1)$, típicamente $y = 1/(1 + x)$, de modo que $x = (1 - y)/y$ y $dx = dy/y^2$. Así,

$$\int_0^\infty g(x) dx = \int_0^1 \frac{g\left(\frac{1-y}{y}\right)}{y^2} dy,$$

y esta última integral, definida sobre $(0, 1)$, ya se puede estimar por Monte Carlo de la forma usual. Cuando el integrando es una función par y el intervalo es $(-\infty, \infty)$, basta con calcular dos veces la integral sobre $(0, \infty)$.

¿Qué es el método de la transformada inversa para variables discretas?

Dada una variable aleatoria discreta X que toma valores $x_1 < x_2 < \dots < x_k$ con probabilidades $p_1, \dots, p_k$, el método de la transformada inversa consiste en generar un número aleatorio uniforme $U \sim \text{Unif}(0, 1)$ y devolver el valor x_j tal que

$$F(x_{j-1}) \leq U < F(x_j),$$

donde F es la función de distribución acumulada de X . En la práctica esto se implementa acumulando las probabilidades $p_1, p_1 + p_2, \dots$ y buscando la primera posición en la que la suma acumulada supera a U .

¿En qué consiste el método de composición?

El método de composición se aplica cuando la función de probabilidad de X se puede escribir como una mezcla de dos (o más) distribuciones más sencillas de simular, es decir,

$$p_j = \alpha q_j + (1 - \alpha) r_j, \quad 0 \leq \alpha \leq 1.$$

El algoritmo genera primero un número aleatorio U_1 : si $U_1 < \alpha$, la variable se simula a partir de la distribución q ; en caso contrario, se simula a partir de la distribución r . Este método resulta útil cuando alguna de las distribuciones componentes (por ejemplo, una uniforme discreta) es mucho más simple de generar que la distribución original completa.

¿Qué es un generador congruencial mixto (lineal)?

Es un algoritmo determinístico para generar secuencias de números que se comportan como pseudoaleatorios uniformes en $(0, 1)$. A partir de una semilla X_0 , cada nuevo término se obtiene mediante la recursión

$$X_{n+1} = (aX_n + c) \bmod m, \quad U_n = X_n/m,$$

donde a es el multiplicador, c es el incremento y m es el módulo. La elección adecuada de estos parámetros determina el período y la calidad estadística de la secuencia generada.

¿Qué es una variable aleatoria de Poisson y cómo se genera?

La distribución de Poisson con parámetro λ modela el número de eventos que ocurren en un intervalo fijo, cuando estos eventos suceden de manera independiente a una tasa promedio constante λ . Su función de probabilidad es

$$P(X = i) = e^{-\lambda} \frac{\lambda^i}{i!}, \quad i = 0, 1, 2, \dots$$

Para generarla, esta práctica implementa el algoritmo secuencial del Capítulo 4 de Ross: se parte de $p = e^{-\lambda}$ y $F = p$; se genera $U \sim \text{Unif}(0, 1)$; si $U < F$ se devuelve $X = 0$; en caso contrario se actualiza $p \leftarrow \frac{\lambda}{X+1}p$, $F \leftarrow F + p$ y $X \leftarrow X + 1$, repitiendo la comparación hasta que $U < F$.

¿Qué es una variable aleatoria Binomial y cómo se genera?

La distribución Binomial con parámetros n y p modela el número de éxitos en n ensayos independientes de Bernoulli, cada uno con probabilidad de éxito p . Su función de probabilidad es

$$P(X = i) = \binom{n}{i} p^i (1 - p)^{n-i}, \quad i = 0, 1, \dots, n.$$

Esta práctica la genera mediante el algoritmo recursivo del Capítulo 4 de Ross, que aprovecha la relación entre probabilidades consecutivas

$$P(X = i + 1) = \frac{n - i}{i + 1} \cdot \frac{p}{1 - p} \cdot P(X = i),$$

partiendo de $P(X = 0) = (1 - p)^n$ y aplicando transformada inversa sobre esa recursión.

3 Fundamento teórico

El desarrollo de esta práctica se apoya en el Capítulo 3 (*Generation of random variables*) y el Capítulo 4 (*Generation of discrete random variables*) del texto de Ross [1], así como en el Capítulo 1 de *Handbook of Simulation* [2], particularmente en la sección 1.11.1 (*Statistical Confidence and Run Length*) para el cálculo de los intervalos de confianza.

La sección 5.2 desarrolla el uso de números aleatorios para aproximar integrales por el método de Monte Carlo, incluyendo integrales dobles y con límites infinitos. La sección 5.3 desarrolla la generación de variables aleatorias discretas mediante el método de la transformada inversa y el método de composición, usando como fuente de números pseudoaleatorios un generador congruencial mixto con parámetros $X_0 = 2391$, $a = 25214903917$, $c = 11$ y $m = 2^{48}$, indicados en la guía. Finalmente, la sección 5.4 retoma el caso ad hoc de la simulación de una cola de un solo servidor desarrollado en la Práctica 1, sustituyendo los generadores basados en dados/ruletas (uniforme discreta) por generadores propios de una variable Poisson (para los tiempos entre llegadas) y una variable Binomial (para los tiempos de servicio).

4 Procedimiento y resultados

4.1 5.2. Uso de números aleatorios para evaluar integrales

Para cada uno de los ejercicios 3 a 9 del Capítulo 3 de [1] se implementó un estimador Monte Carlo genérico, generando $n = 100,000$ números pseudoaleatorios uniformes por estimación (o $n = 200,000$ en el caso de las integrales dobles). Cuando el límite de integración era infinito se aplicó la sustitución $y = 1/(1+x)$ descrita en la Consulta previa.

Ejercicio 3

$$\int_0^1 \exp\{e^x\} dx \approx 6.299839$$

Ejercicio 4

$$\int_0^1 (1-x^2)^{3/2} dx \approx 0.590955 \quad (\text{valor analítico } 3\pi/16 = 0.589049)$$

Ejercicio 5

$$\int_{-2}^2 e^{x+x^2} dx \approx 92.978184$$

Ejercicio 6

$$\int_0^\infty x(1+x^2)^{-2} dx \approx 0.500928 \quad (\text{valor analítico } 1/2 = 0.500000)$$

Ejercicio 7

$$\int_{-\infty}^{\infty} e^{-x^2} dx \approx 1.767204 \quad (\text{valor analítico } \sqrt{\pi} = 1.772454)$$

Ejercicio 8

$$\int_0^1 \int_0^1 e^{(x+y)^2} dy dx \approx 4.902697$$

Ejercicio 9

$$\int_0^{\infty} \int_0^x e^{-(x+y)} dy dx \approx 0.500137$$

Tabla 1: Resumen de las estimaciones Monte Carlo – sección 5.2

Ejercicio	Integral	Estimación Monte Carlo
3	$\int_0^1 \exp\{e^x\} dx$	6.299839
4	$\int_0^1 (1-x^2)^{3/2} dx$	0.590955
5	$\int_{-2}^2 e^{x+x^2} dx$	92.978184
6	$\int_0^{\infty} x(1+x^2)^{-2} dx$	0.500928
7	$\int_{-\infty}^{\infty} e^{-x^2} dx$	1.767204
8	$\int_0^1 \int_0^1 e^{(x+y)^2} dy dx$	4.902697
9	$\int_0^{\infty} \int_0^x e^{-(x+y)} dy dx$	0.500137

Análisis. En los ejercicios en los que se cuenta con un valor analítico de referencia (4, 6 y 7), la estimación Monte Carlo se aproxima adecuadamente al valor teórico, con errores relativos pequeños (por ejemplo, 0.32 % en el Ejercicio 6 y 0.30 % en el Ejercicio 7), lo que confirma que $n = 100,000$ números pseudoaleatorios es suficiente para obtener una buena precisión en integrales de este tipo.

4.2 5.3. Generación de variables aleatorias discretas

Para toda la sección se usó el generador congruencial mixto (GLC) con los parámetros indicados en la guía: $X_0 = 2391$, $a = 25214903917$, $c = 11$, $m = 2^{48}$.

5.3.a. $p_1 = 0.20$, $p_2 = 0.15$, $p_3 = 0.25$, $p_4 = 0.40$

Se generaron 100 valores de $X \in \{1, 2, 3, 4\}$ por transformada inversa. Los primeros 20 valores obtenidos fueron: 2 4 4 4 4 3 4 4 3 4 2 1 4 4 1 1 1 1 2 3.

5.3.b. $P(X = 1) = 0.30$, $P(X = 2) = 0.20$, $P(X = 3) = 0.35$, $P(X = 4) = 0.15$

Los primeros 20 valores generados fueron: 1 3 3 3 3 2 3 4 2 3 2 1 3 3 1 1 1 1 1 2.

Tabla 2: 5.3.a – Frecuencias observadas vs. teóricas ($n = 100$)

x	Probabilidad teórica	Frecuencia observada
1	0.20	0.21
2	0.15	0.14
3	0.25	0.27
4	0.40	0.38

Tabla 3: 5.3.b – Frecuencias observadas vs. teóricas ($n = 100$)

x	Probabilidad teórica	Frecuencia observada
1	0.30	0.32
2	0.20	0.22
3	0.35	0.29
4	0.15	0.17

5.3.c. $p_1 = 1/3$, $p_2 = 2/3$

Se generó la variable con $n = 100$, $n = 1,000$ y $n = 10,000$, calculando en cada caso la proporción de valores iguales a 1 (valor teórico esperado: $1/3 = 0.3333$).

Tabla 4: 5.3.c – Proporción muestral de $X = 1$ según el tamaño de muestra

n	Proporción de $X = 1$	Valor teórico
100	0.3400	0.3333
1 000	0.3280	0.3333
10 000	0.3316	0.3333

Observación. A medida que n aumenta, la proporción muestral de valores iguales a 1 converge hacia el valor teórico $p_1 = 1/3$, ilustrando la Ley de los Grandes Números.

5.3.d. Método de composición

$X \in \{1, \dots, 10\}$ con probabilidades 0.06, 0.06, 0.06, 0.06, 0.06, 0.15, 0.13, 0.14, 0.15, 0.13. Se descompuso $p_j = \alpha q_j + (1 - \alpha) r_j$ con $\alpha = 0.6$, $q_j = 1/10$ para $j = 1, \dots, 10$, y r_j definida solo sobre $\{6, \dots, 10\}$:

$$r_6 = 0.225, \quad r_7 = 0.175, \quad r_8 = 0.200, \quad r_9 = 0.225, \quad r_{10} = 0.175 \quad (\sum r_j = 1.000).$$

Los primeros 20 valores generados fueron: 8 9 7 10 8 1 9 2 2 5 8 4 10 10 6 7 7 7 6 9.

Análisis. En los cuatro literales, las frecuencias observadas con $n = 100$ se aproximan razonablemente a las probabilidades teóricas, aunque con las diferencias esperadas propias de una muestra de tamaño moderado; el literal 5.3.c confirma explícitamente que dichas diferencias se reducen a medida que crece el tamaño de la muestra.

Tabla 5: 5.3.d – Frecuencias observadas vs. teóricas ($n = 100$)

x	Probabilidad teórica	Frecuencia observada
1	0.06	0.09
2	0.06	0.06
3	0.06	0.00
4	0.06	0.12
5	0.06	0.09
6	0.15	0.15
7	0.13	0.17
8	0.14	0.13
9	0.15	0.07
10	0.13	0.12

4.3 5.4. Simulación Ad Hoc con generadores propios (Poisson y Binomial)

4.3.1 Generadores propios de variables aleatorias

Se implementaron los algoritmos descritos en la Consulta previa para $\text{Poisson}(\lambda)$ y $\text{Binomial}(n, p)$. Como verificación, se generaron 20 000 realizaciones de cada uno con $\lambda = 10$ y $(n, p) = (10, 0.40)$, obteniendo:

Tabla 6: Verificación de los generadores propios ($n = 20,000$ realizaciones)

Variable	Media empírica	Media teórica
$\text{Poisson}(\lambda = 10)$	10.0286	10.0
$\text{Binomial}(n = 10, p = 0.40)$	3.9874	4.0

Ambas medias empíricas son muy cercanas a las teóricas, lo que valida el correcto funcionamiento de los dos generadores propios antes de emplearlos en la simulación de la cola.

4.3.2 Simulación con 20 clientes

Se repitió la lógica de simulación de la Práctica 1: el primer cliente llega en $t = 0$ sin tiempo entre llegadas; para los siguientes, el tiempo entre llegadas se genera con el Poisson propio ($\lambda = 10$) y el tiempo de servicio con el Binomial propio ($n = 10, p = 0.40$). La Tabla 7 muestra la corrida obtenida con semilla 1.

Tabla 7: Simulación Ad Hoc – 20 clientes (Poisson/Binomial propios)

Cliente	Tiempo entre llegadas	Hora de llegada	Tiempo de servicio	Inicio de servicio	Fin de servicio	Tiempo en el sistema	Tiempo ocioso	Tiempo en cola
1	–	0	0	0	0	0	0	0

Cliente	Tiempo entre llegadas	Hora de llegada	Tiempo de servicio	Inicio de servicio	Fin de servicio	Tiempo en el sistema	Tiempo ocioso	Tiempo en cola
2	11	11	4	11	15	4	11	0
3	7	18	2	18	20	2	3	0
4	9	27	4	27	31	4	7	0
5	5	32	5	32	37	5	1	0
6	10	42	3	42	45	3	5	0
7	10	52	3	52	55	3	7	0
8	8	60	3	60	63	3	5	0
9	4	64	7	64	71	7	1	0
10	13	77	5	77	82	5	6	0
11	8	85	4	85	89	4	3	0
12	11	96	4	96	100	4	7	0
13	6	102	2	102	104	2	2	0
14	7	109	6	109	115	6	5	0
15	9	118	3	118	121	3	3	0
16	8	126	3	126	129	3	5	0
17	10	136	7	136	143	7	7	0
18	7	143	2	143	145	2	0	0
19	15	158	6	158	164	6	13	0
20	12	170	4	170	174	4	6	0

4.3.3 Medidas de desempeño

Tabla 8: Medidas de desempeño – simulación de 20 clientes (Poisson/Binomial propios)

Medida de desempeño	Valor
Tiempo promedio en el sistema	3.8500
Porcentaje de tiempo ocioso	0.5575
Tiempo de espera promedio por cliente	0.0000
Fracción de clientes que esperó	0.0000
Tiempo de espera promedio de quienes esperaron	0.0000

Interpretación. En esta corrida en particular ningún cliente tuvo que esperar en cola (las cinco columnas relacionadas con la espera son cero), lo que se explica porque el tiempo promedio entre llegadas (Poisson con media 10) es notablemente mayor que el tiempo promedio de servicio (Binomial con media 4): en la mayoría de los casos el servidor ya había terminado de atender al cliente anterior antes de que llegara el siguiente. En consecuencia, el porcentaje de tiempo ocioso del servidor es alto (55.75 %).

4.3.4 Repetición de la simulación (10 corridas)

Siguiendo el mismo esquema de la Práctica 1, se repitió el procedimiento 10 veces, cambiando la semilla del generador en cada corrida. Los resultados se presentan en la Tabla 9.

Tabla 9: Resultados de las 10 corridas – 20 clientes (Poisson/Binomial propios)

Corrida	Tiempo prom. en sistema	% tiempo ocioso	Espera prom. por cliente	Fracción que esperó	Espera prom. de quienes esperaron
1	4.20	0.5692	0.000	0.000	0.000
2	4.25	0.5829	0.100	0.050	2.000
3	3.75	0.6250	0.000	0.000	0.000
4	3.90	0.6100	0.000	0.000	0.000
5	3.55	0.6302	0.000	0.000	0.000
6	4.15	0.5598	0.100	0.050	2.000
7	3.90	0.6100	0.000	0.000	0.000
8	4.30	0.5779	0.100	0.050	2.000
9	3.30	0.6827	0.000	0.000	0.000
10	3.40	0.6059	0.050	0.050	1.000
Media	3.870	0.6054	0.035	0.020	0.700

Análisis. A diferencia de la Práctica 1, en la que la fracción de clientes que esperaba oscilaba entre 0.10 y 0.40, en esta práctica dicha fracción es mucho menor (entre 0.00 y 0.05 en las 10 corridas), y en cinco de las diez corridas ningún cliente tuvo que esperar. Esto confirma, de manera consistente entre corridas, que las distribuciones Poisson y Binomial empleadas producen un sistema con mucha menor congestión que el de la Práctica 1.

4.3.5 Intervalos de confianza (95 % y 99 %)

Para cada medida de desempeño se calculó la media muestral $\bar{X}$, la desviación estándar muestral S , la media anchura $h = t_{n-1, 1-\alpha/2} S/\sqrt{n}$ y el intervalo $[\bar{X} - h, \bar{X} + h]$, con $n = 10$ corridas. Los resultados se muestran en la Tabla 10.

Análisis. En las medidas relacionadas con la espera en cola (espera promedio por cliente, fracción que esperó y espera promedio de quienes esperaron), el intervalo de confianza al 99 % incluye valores negativos en su límite inferior, lo cual es una consecuencia esperable de que la variable subyacente esté acotada por debajo en cero y de que la mayoría de las corridas hayan arrojado valores muy cercanos a cero: al tratarse de una aproximación basada en la distribución t de Student (que asume simetría), el intervalo puede extenderse por debajo del rango posible de la medida. En la práctica, estos límites negativos se interpretan simplemente como que el verdadero promedio poblacional podría estar arbitrariamente cerca de cero.

4.3.6 Comparación con los resultados de la Práctica 1

En la Práctica 1, los tiempos entre llegadas se generaron con una uniforme discreta $U\{1, 10\}$ (media 5.5) y los tiempos de servicio con una uniforme discreta $U\{1, 6\}$ (media 3.5). En esta práctica se

Tabla 10: Intervalos de confianza 95 % y 99 % – simulación de 20 clientes con Poisson/Binomial (10 corridas)

Medida	Conf.	$\bar{X}$	S	$t_{n-1, 1-\alpha/2}$	h	IC inf.	IC sup.
Tiempo prom. en el sistema	95 %	3.8700	0.3622	2.2622	0.2591	3.6109	4.1291
Tiempo prom. en el sistema	99 %	3.8700	0.3622	3.2498	0.3723	3.4977	4.2423
% tiempo ocioso	95 %	0.6054	0.0360	2.2622	0.0258	0.5796	0.6311
% tiempo ocioso	99 %	0.6054	0.0360	3.2498	0.0370	0.5684	0.6424
Espera prom. por cliente	95 %	0.0350	0.0474	2.2622	0.0339	0.0011	0.0689
Espera prom. por cliente	99 %	0.0350	0.0474	3.2498	0.0487	-0.0137	0.0837
Fracción que esperó	95 %	0.0200	0.0258	2.2622	0.0185	0.0015	0.0385
Fracción que esperó	99 %	0.0200	0.0258	3.2498	0.0265	-0.0065	0.0465
Espera prom. de quienes esperaron	95 %	0.7000	0.9487	2.2622	0.6786	0.0214	1.3786
Espera prom. de quienes esperaron	99 %	0.7000	0.9487	3.2498	0.9750	-0.2750	1.6750

usan Poisson($\lambda = 10$) (media 10) para las llegadas y Binomial($n = 10, p = 0.4$) (media 4) para el servicio.

Tabla 11: Comparación de medidas de desempeño promedio – 20 clientes

Medida de desempeño	Práctica 1 (uniforme)	Práctica 2 (Poisson/Binomial)
Tiempo promedio en el sistema	4.470	3.870
Porcentaje de tiempo ocioso	0.358	0.605
Tiempo de espera promedio por cliente	0.930	0.035
Fracción de clientes que esperó	0.295	0.020
Tiempo de espera promedio de quienes esperaron	3.006	0.700

Análisis. Como se anticipó, el mayor espaciamiento entre llegadas (media 10 frente a 5.5) se traduce en un porcentaje de tiempo ocioso considerablemente mayor (60.5 % frente a 35.8 %) y en una reducción muy marcada de las medidas relacionadas con la espera: la fracción de clientes que esperó cae de 0.295 a 0.020, y el tiempo de espera promedio de quienes sí esperaron baja de 3.006 a 0.700 minutos. Esto confirma que, aun manteniendo el mismo tipo de sistema (cola con un solo servidor) y el mismo número de clientes por corrida, la elección de la distribución de los tiempos entre llegadas y de servicio tiene un efecto determinante sobre el nivel de congestión observado.

5 Conclusiones

- El método de Monte Carlo permite aproximar con buena precisión integrales definidas, incluso integrales dobles y con límites infinitos, siempre que se use un número suficientemente grande de números pseudoaleatorios y, en el caso de límites infinitos, el cambio de variable adecuado.
- El método de la transformada inversa y el método de composición son dos formas equivalentes, aunque con distinta complejidad de implementación, de generar variables aleatorias discretas a partir de números pseudoaleatorios uniformes; el método de composición resulta particular-

mente útil cuando la distribución original se puede descomponer en distribuciones más simples de simular.

- Los generadores propios de Poisson y Binomial, implementados con los algoritmos secuencial y recursivo del Capítulo 4 de Ross, reproducen adecuadamente las medias teóricas de dichas distribuciones al evaluarlos sobre una muestra grande.
- Al sustituir, en la simulación de la cola, la distribución uniforme discreta de la Práctica 1 por las distribuciones Poisson y Binomial de esta práctica, el sistema resultó considerablemente menos congestionado: mayor porcentaje de tiempo ocioso del servidor y una fracción mucho menor de clientes que debieron esperar. Esto ilustra que las medidas de desempeño de un sistema de colas dependen críticamente de la forma y los parámetros de las distribuciones que gobiernan los tiempos entre llegadas y de servicio, y no únicamente de sus valores promedio.
- Como en la Práctica 1, una sola corrida de la simulación no es suficiente para caracterizar el sistema: fue necesario repetir la simulación 10 veces y calcular intervalos de confianza para tener una estimación confiable de cada medida de desempeño.

6 Anexos

Junto con este informe se entrega el siguiente archivo:

- `Lab2_5_2_5_3_5_4.ipynb` – notebook de Jupyter/Google Colab con la implementación completa de las secciones 5.2, 5.3 y 5.4, incluyendo el código de los generadores propios, la simulación de la cola y el cálculo de los intervalos de confianza.

Referencias

- [1] Ross, S. M. (1999). *Simulation* (2nd ed.). Academic Press.
- [2] Banks, J. (1998). *Handbook of Simulation: Principles, Methodology, Advances, Applications, and Practice*. John Wiley & Sons, Inc.